

Universidade do Estado do Rio de Janeiro
Centro de Tecnologia e Ciências
Instituto de Matemática, Estatística e
Computação

Pedro Caetano Pires

Detecção de Lavagem de Dinheiro via Grafos Temporais e XGBoost: Um Estudo de Ablação sobre Atributos Topológicos

Rio de Janeiro
2026

Pedro Caetano Pires

Detecção de Lavagem de Dinheiro via Grafos Temporais e XGBoost: Um Estudo de Ablação sobre Atributos Topológicos

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Ciência da Computação, ao Instituto de Matemática, Estatística e Computação, da Universidade do Estado do Rio de Janeiro.

Orientador: Prof. D.Sc. Bruno Porto Masquio

Rio de Janeiro

2026

CATALOGAÇÃO NA FONTE
UERJ / REDE SIRIUS / BIBLIOTECA CTC/D

ISTO É APENAS DEMONSTRATIVO
DEVE SER SUBSTITUÍDO PELA FICHA CATALOGRÁFICA QUE A BIBLIOTECA PROVIDENCIAR.

D979 Caetano Pires, Pedro

Detecção de Lavagem de Dinheiro via Grafos Temporais e XGBoost: Um Estudo de Ablação sobre Atributos Topológicos / Pedro Caetano Pires. – Rio de Janeiro, 2026-

66 f.

Orientador: Prof. D.Sc. Bruno Porto Masquio

Trabalho de Conclusão de Curso (Graduação) – Universidade do Estado do Rio de Janeiro, Instituto de Matemática, Estatística e Computação, Instituto de Matemática, Estatística e Computação, 2026.

1. Lavagem de Dinheiro;. 2. Grafos Temporais;. 3. XGBoost;. I. Prof. D.Sc. Bruno Porto Masquio. II. Universidade do Estado do Rio de Janeiro. III. Instituto de Matemática, Estatística e Computação. IV. Título

CDU 02:141:005.7

Autorizo, apenas para fins acadêmicos e científicos, a reprodução total ou parcial desta trabalho de conclusão de curso, desde que citada a fonte.

Assinatura

Data

Pedro Caetano Pires

Detecção de Lavagem de Dinheiro via Grafos Temporais e XGBoost: Um Estudo de Ablação sobre Atributos Topológicos

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Ciência da Computação, ao Instituto de Matemática, Estatística e Computação, da Universidade do Estado do Rio de Janeiro.

Aprovada em dia de mês de 2026.

Banca Examinadora:

Prof. D.Sc. Bruno Porto Masquio (Orientador)
Instituto de Matemática, Estatística e Computação – UERJ

Prof. D.Sc. Bruno Porto Masquio (Orientador)
Instituto de Matemática, Estatística e Computação – UERJ

Prof. Título Nome Completo
Instituto de Matemática, Estatística e Computação – UERJ

Prof. Título Nome Completo
Instituto de Matemática, Estatística e Computação – UERJ

Rio de Janeiro
2026

DEDICATÓRIA

Aos meus pais, com profunda gratidão por todo o apoio, incentivo e dedicação ao longo desta jornada.

AGRADECIMENTOS

Agradeço à Universidade do Estado do Rio de Janeiro (UERJ) e ao Instituto de Matemática, Estatística e Computação (IMEC) por proporcionarem um ambiente de formação de excelência.

Ao meu orientador, Prof. D.Sc. Bruno Porto Masquio, pela orientação, disponibilidade, confiança e discussões acadêmicas que guiaram a consolidação deste trabalho.

A todos os professores que tive ao longo do curso, por cada aula, conselho e ensinamento compartilhado.

Aos meus pais e familiares, por sempre me apoiarem e incentivarem meus estudos e aspirações.

Aos amigos e colegas de curso, pelas horas compartilhadas de estudo, companheirismo e apoio mútuo ao longo de toda a graduação.

A todos que, direta ou indiretamente, contribuíram para a realização deste projeto.

Information is the resolution of uncertainty.

Claude Shannon

RESUMO

CAETANO PIRES, P.C.P. **Detecção de Lavagem de Dinheiro via Grafos Temporais e XGBoost: Um Estudo de Ablação sobre Atributos Topológicos**. 2026. 66 f. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) – Instituto de Matemática, Estatística e Computação, Universidade do Estado do Rio de Janeiro, Rio de Janeiro, 2026.

Embora a lavagem de dinheiro movimente entre 2% e 5% do PIB mundial, os métodos tradicionais de detecção ainda falham ao analisar contas de forma isolada. Dependentes de heurísticas rígidas, esses sistemas não conseguem mapear as tipologias complexas que se aproveitam da estrutura da rede transacional. Neste trabalho, investigamos como atributos topológicos extraídos de grafos temporais podem mitigar essa lacuna utilizando o algoritmo XGBoost. Para isso, estruturamos um estudo de ablação controlado para comparar um modelo base, treinado com 21 *features* comportamentais, a um modelo completo composto por 49 atributos (as 21 comportamentais somadas a 28 variáveis topológicas). Avaliamos a abordagem em dois *datasets* sintéticos do AMLworld: HI Small (1.245.666 transações, 1,15% de fraude) e HI Medium (7.376.519 transações, 1,35% de fraude), ambos processados via janelas temporais deslizantes para respeitar a causalidade estrita. A introdução de métricas de rede (como centralidade, detecção de comunidades e padrões de vizinhança) gerou melhorias estatisticamente significativas. No HI Small, observamos aumentos de +18,00% em AUPRC ($p = 0{,}0188$), +46,67% em precisão ($p = 0{,}0070$) e +41,86% em F1-Score ($p = 0{,}0055$). O ganho se manteve robusto no HI Medium, com altas de +18,88% em AUPRC, +32,28% em precisão e +29,04% em F1-Score. Por fim, a análise SHAP confirmou o papel decisivo das variáveis de grafo, destacando métricas como HITS, grau de entrada e modularidade de comunidades entre os principais preditores. Os resultados comprovam que o comportamento fraudulento deixa uma assinatura estrutural clara e persistente na rede transacional, mantendo-se consistente independentemente da escala dos dados.

Palavras-chave: Lavagem de Dinheiro; Grafos Temporais; XGBoost; Ciência de Dados de Grafos.

ABSTRACT

CAETANO PIRES, P.C.P. **Money Laundering Detection via Temporal Graphs and XGBoost: An Ablation Study on Topological Features**. 2026. 66 f. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) – Instituto de Matemática, Estatística e Computação, Universidade do Estado do Rio de Janeiro, Rio de Janeiro, 2026.

While money laundering circulates between 2% and 5% of global GDP, traditional detection systems still struggle to contain it. Relying on rigid heuristics, these systems fail to capture the complex, multi-party typologies that exploit the underlying structure of the transaction network. In this work, we investigate how topological features extracted from temporal graphs can close this gap using the XGBoost algorithm. We designed a controlled ablation study to isolate the impact of network structure, comparing a baseline model trained on 21 behavioral features against an expanded model with 49 attributes (adding 28 topological features). We evaluated both models on two synthetic datasets from AMLworld: HI Small (1,245,666 transactions, 1.15% fraud) and HI Medium (7,376,519 transactions, 1.35% fraud). To respect strict temporal causality, we processed both datasets using sliding time windows. Integrating graph metrics (such as centrality, community detection, and neighborhood patterns) yielded statistically significant performance gains across both benchmarks. On HI Small, the structural features boosted AUPRC by +18.00% ($p = 0.0188$), precision by +46.67% ($p = 0.0070$), and F1-Score by +41.86% ($p = 0.0055$). These gains remained robust on the larger HI Medium dataset, showing improvements of +18.88% in AUPRC, +32.28% in precision, and +29.04% in F1-Score. Finally, SHAP analysis confirmed the decisive role of graph features, placing metrics like HITS, in-degree, and community modularity among the top predictors. This validates our hypothesis that illicit actors leave distinct, scale-invariant structural signatures on the financial network.

Keywords: Money Laundering; Temporal Graphs; XGBoost; Graph Data Science.

LISTA DE FIGURAS

Figura 1 - As três fases clássicas da lavagem de dinheiro 17
Figura 2 - Fan-in, Fan-out e Ciclo Direcionado em Grafos Financeiros 31
Figura 3 - Comparação de métricas entre os modelos Baseline e Full Model (HI Small) 36
Figura 4 - Comparação de métricas entre os modelos Baseline e Full Model (HI Medium) 37
Figura 5 - Comparação de Precision@k entre os modelos Baseline e Full Model (HI Small) 38
Figura 6 - Comparação de Precision@k entre os modelos Baseline e Full Model (HI Medium) 39
Figura 7 - Captura de entidades fraudulentas: Baseline vs Full Model (HI Small) . 43
Figura 8 - Captura de entidades fraudulentas: Baseline vs Full Model (HI Medium) 44
Figura 9 - Distribuição de valores SHAP para as principais features do modelo (HI Small) 47
Figura 10 - Distribuição de valores SHAP para as principais features do modelo (HI Medium) 49
Figura 11 - Comparação de AUPRC e Lift percentual por janela temporal (HI Small) 54
Figura 12 - Ganho absoluto de AUPRC (ΔAUPRC) por janela temporal (HI Small) 55
Figura 13 - Precisão@100 por janela temporal no estudo de ablação (HI Small) . . 56
Figura 14 - Comparação de AUPRC e Lift percentual por janela temporal (HI Medium) 57
Figura 15 - Ganho absoluto de AUPRC (ΔAUPRC) por janela temporal (HI Medium) 58
Figura 16 - Precisão@100 por janela temporal no estudo de ablação (HI Medium) . 59

LISTA DE TABELAS

Tabela 1 - Resumo das variações do *dataset* AMLworld 25
Tabela 2 - Desempenho dos modelos no dataset HI Small 35
Tabela 3 - Desempenho dos modelos no dataset HI Medium 37
Tabela 4 - Comparação de desempenho por janela temporal 39
Tabela 5 - Comparação de desempenho por janela temporal (HI Medium - seleção) 40
Tabela 6 - Testes de significância estatística (HI Small, teste t pareado, $\alpha = 0{,}05$) 41
Tabela 7 - Testes de significância estatística (HI Medium, teste t pareado, $\alpha = 0{,}05$) 42
Tabela 8 - Top 15 features por importância SHAP global (HI Small) 45
Tabela 9 - Top 15 features por importância SHAP global (HI Medium) 50
Tabela 10 - Resumo comparativo dos agrupamentos métricos estruturais 52

LISTA DE ABREVIATURAS E SIGLAS

ACH	*Automated Clearing House*
AML	*Anti-Money Laundering*
AUPRC	*Area Under the Precision-Recall Curve*
COAF	Conselho de Controle de Atividades Financeiras
FN	*False Negative*
FP	*False Positive*
FPR	*False Positive Rate*
GAFI	Grupo de Ação Financeira contra a Lavagem de Dinheiro e o Financiamento do Terrorismo
HITS	*Hyperlink-Induced Topic Search*
PIB	Produto Interno Bruto
ROC-AUC	*Receiver Operating Characteristic - Area Under the Curve*
SHAP	*SHapley Additive exPlanations*
TN	*True Negative*
TP	*True Positive*
TPR	*True Positive Rate*
USD	*United States Dollar*
XGBoost	*eXtreme Gradient Boosting*

LISTA DE SÍMBOLOS

α	Fator de amortecimento do algoritmo PageRank
Δt	Tamanho da janela temporal deslizante
γ	Parâmetro de resolução do algoritmo Leiden
ρ	Coeficiente de correlação de Spearman
$G = (V, E)$	Grafo composto por vértices V e arestas E
w_{vol}	Peso da aresta baseado em volume financeiro
w_{count}	Peso da aresta baseado em contagem de transações

SUMÁRIO

1 **INTRODUÇÃO** . . . 14
2 **FUNDAMENTAÇÃO TEÓRICA** . . . 16
2.1 **Lavagem de Dinheiro e Tipologias Transacionais** . . . 16
2.2 **Métricas de Avaliação** . . . 17
2.2.1 Matriz de Confusão . . . 18
2.2.2 Métricas de Desempenho e o Problema do Desbalanceamento . . . 18
2.2.2.1 Área sob a Curva ROC (ROC-AUC) . . . 19
2.2.2.2 Área sob a Curva Precisão-Recall (AUPRC) . . . 19
2.2.2.3 Precisão nos Primeiros k Alertas (Precision@k) . . . 20
2.3 **Teoria dos Grafos** . . . 20
2.3.1 Grafos Temporais . . . 21
2.3.2 Atributos Topológicos . . . 21
2.3.2.1 Métricas de Centralidade e Coesão . . . 22
2.3.2.2 Detecção de Comunidades . . . 23
2.3.2.3 Padrões de Vizinhança e *Motifs* . . . 24
3 **METODOLOGIA E DESENVOLVIMENTO** . . . 25
3.1 **Base de Dados** . . . 25
3.1.1 Pré-processamento e Padronização dos Dados . . . 26
3.2 **Modelagem da Janela Deslizante e Agregação de Arestas** . . . 26
3.3 **Engenharia de *Features* Topológicas** . . . 28
3.3.1 Métricas de Centralidade e Coesão . . . 28
3.3.2 Detecção de Comunidades (Leiden) . . . 29
3.3.3 Padrões de Vizinhança, Agregação e *Motifs* . . . 30
3.4 **Arquitetura Preditiva e Calibração de Limiar com XGBoost** . . . 31
3.4.1 Divisão Cronológica dos Dados (*Forward-Chaining*) . . . 31
3.5 **Modelos Preditivos e Avaliação de Desempenho** . . . 32
3.5.1 Ponderação Dinâmica da Função de Perda . . . 33
3.5.2 Estudo de Ablação . . . 33
4 **RESULTADOS E DISCUSSÃO** . . . 35
4.1 **Desempenho dos Modelos Baseline e Full** . . . 35
4.1.1 Resultados no Dataset HI Small . . . 35
4.1.2 Resultados no Dataset HI Medium . . . 36
4.1.3 Análise Comparativa Entre Datasets . . . 38
4.1.4 Métrica Precision@k e Eficácia Operacional . . . 38
4.1.5 Análise de Desempenho Temporal no HI Small . . . 39
4.1.6 Análise de Desempenho Temporal no HI Medium . . . 40

4.2 **Validação Estatística do Estudo de Ablação** . . . 41
4.2.1 Testes Estatísticos no HI Small . . . 41
4.2.2 Testes Estatísticos no HI Medium . . . 42
4.3 **Captura de Entidades Fraudulentas em Nível Operacional** . . . 42
4.3.1 Análise em Nível de Entidades . . . 42
4.4 **Importância Global das Features via SHAP** . . . 44
4.4.1 Análise SHAP no HI Small . . . 44
4.4.2 Análise SHAP no HI Medium . . . 48
4.5 **Métricas Topológicas dos Algoritmos** . . . 51
4.5.1 O Paradoxo Estrutural do Algoritmo de Leiden . . . 52
4.6 **Discussão dos Resultados** . . . 53
5 **CONCLUSÃO** . . . 60
5.1 **Principais Contribuições** . . . 60
5.2 **Implicações Práticas** . . . 60
5.3 **Limitações e Trabalhos Futuros** . . . 61
5.4 **Considerações Finais** . . . 62
REFERÊNCIAS BIBLIOGRÁFICAS . . . 63

1 INTRODUÇÃO

"Follow the money."
Henry E. Peterson

A lavagem de dinheiro consiste em reinserir na economia recursos obtidos de forma ilícita, ocultando sua origem (Conselho de Controle de Atividades Financeiras, 2021). Segundo United Nations Office on Drugs and Crime (2011), esse crime movimenta entre 2% e 5% do PIB mundial por ano. No Brasil, estima-se que entre US$ 25,8 bilhões e US$ 64,4 bilhões sejam lavados anualmente (VinciWorks, 2014; KAR, 2014; Working Group for National Risk Assessment, 2023), o que exige das instituições financeiras sistemas de monitoramento em larga escala. Tradicionalmente, a detecção de anomalias em AML (*Anti-Money Laundering*) baseia-se em heurísticas e regras estáticas, centradas em limites de valor e frequência transacional. Essa abordagem tende a gerar altas taxas de falsos positivos, sobrecarregar equipes de *compliance* e falhar na identificação de tipologias criminosas mais recentes, nas quais os fraudadores fragmentam os valores em múltiplas contas e camadas de ofuscação (JENSEN; IOSIFIDIS, 2023).

Como forma de mascarar suas atividades, criminosos realizam suas operações explorando propriedades topológicas específicas, como *smurfing*, ciclos de transferência e nós de dispersão, para cortar o rastro do dinheiro (CHENG; ZOU; XIANG, 2025; DUMITRESCU; BĂLTOIU; BUDULAN, 2022; FATF; Egmont Group, 2023). Enquanto a análise tabular tradicional avalia o comportamento de uma conta de forma isolada, a aplicação de Ciência de Dados de Grafos permite extrair métricas de centralidade, detecção de comunidades, informações topológicas e anomalias de vizinhança que capturam dados sobre o comportamento dos participantes da rede (BAIGABYL; NUGUMANOVA; SODNOMOVA, 2025).

Algoritmos de *Gradient Boosting*, como o XGBoost (CHEN; GUESTRIN, 2016), são amplamente utilizados para análise de dados estruturados devido à eficiência computacional e robustez no tratamento do desbalanceamento extremo de classes, típico da detecção de fraudes (ALARAB; PRAKOONWIT; NACER, 2020). No entanto, o XGBoost puro não processa estruturas relacionais nativamente: existe a necessidade de isolar e quantificar o ganho real de performance que as *features* baseadas em grafos injetam nesses modelos tabulares (KARIM et al., 2024). Além disso, é necessário estabelecer se a complexidade extra de treinar um modelo de *Machine Learning* se justifica frente ao uso direto de algoritmos de grafos isolados atuando como detectores de fraude.

O objetivo principal deste trabalho é investigar e quantificar o impacto da adição de variáveis topológicas de grafos na eficácia do algoritmo XGBoost para a detecção de entidades participantes em esquemas de lavagem de dinheiro, utilizando o *dataset*

AMLworld (ALTMAN et al., 2023).

Como objetivos específicos, definem-se:

- Modelar o *dataset* transacional como uma rede temporal e extrair atributos topológicos, preservando a cronologia estrita através de janelas temporais para impedir o vazamento de dados (*data leakage*).
- Avaliar a capacidade preditiva de algoritmos de grafos atuando de forma isolada na identificação de entidades fraudulentas.
- Implementar um pipeline preditivo baseado em XGBoost com calibração de limiar e pesagem algorítmica dinâmica para mitigar o alto volume de falsos positivos inerente a cenários de detecção de anomalias.
- Conduzir um estudo de ablação sob validação *forward-chaining*, comparando estatisticamente o impacto no desempenho gerado pela adição das *features* topológicas em relação a um modelo de base puramente comportamental.
- Mensurar o impacto operacional e quantificar a captura real de infratores através de diferentes métricas de avaliação de desempenho.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, são apresentados os fundamentos teóricos que sustentam este trabalho. Inicialmente, abordam-se os conceitos centrais sobre o processo de lavagem de dinheiro e suas tipologias operacionais de ocultação, com ênfase na técnica de *smurfing*. Em seguida, são discutidas as métricas de avaliação de modelos preditivos aplicadas ao cenário de desbalanceamento severo de classes e a formulação da Teoria dos Grafos voltada a redes temporais.

2.1 Lavagem de Dinheiro e Tipologias Transacionais

A lavagem de dinheiro compreende o conjunto de operações comerciais ou financeiras que visam a incorporar na economia formal bens, direitos ou valores originados de infrações penais, conferindo-lhes aparência de licitude (Conselho de Controle de Atividades Financeiras, 2021). De acordo com as diretrizes internacionais do Grupo de Ação Financeira contra a Lavagem de Dinheiro e o Financiamento do Terrorismo (GAFI/FATF) e do Conselho de Controle de Atividades Financeiras (Conselho de Controle de Atividades Financeiras, 2021; FATF; Egmont Group, 2023), o processo de lavagem divide-se classicamente em três fases interdependentes, ilustradas na Figura 1:

1. **Colocação (*Placement*):** fase inicial de ingresso dos fundos ilícitos no sistema financeiro ou na economia tradicional, frequentemente realizada por meio de depósitos em espécie fracionados, aquisição de ativos negociáveis ou liquidação de títulos;

2. **Ocultação ou Estratificação (*Layering*):** condução de múltiplos arranjos transacionais, movimentações entre contas intermediárias e transferências entre instituições e jurisdições diversas, cujo propósito é distanciar os fundos de sua origem delituosa e impossibilitar o rastreamento contábil dos recursos;

3. **Integração (*Integration*):** reintrodução definitiva dos valores na economia formal sob a forma de investimentos produtivos, empreendimentos imobiliários ou aquisição de bens de capital, consolidando a falsa aparência de legitimidade dos recursos.

Dentre as técnicas operacionais mais disseminadas nas fases de colocação e ocultação, destaca-se a estruturação de transações, internacionalmente denominada *smurfing* (FATF; Egmont Group, 2023; CHENG; ZOU; XIANG, 2025). O *smurfing* consiste no fracionamento deliberado de um grande montante financeiro em depósitos ou transferências de valores reduzidos, mantidos intencionalmente abaixo dos limites regulatórios que

Figura 1 – As três fases clássicas da lavagem de dinheiro



Fonte: Elaborado pelo autor.

disparam os mecanismos de comunicação obrigatória aos órgãos de supervisão financeira (como o COAF no Brasil).

Para executar esse fracionamento em larga escala, as organizações criminosas utilizam uma rede de executores (frequentemente denominados "laranjas" ou *money mules*) e múltiplas contas correntes abertas em diversas instituições financeiras. Sob a perspectiva de Ciência de Dados de Grafos, essa dinâmica gera padrões estruturais específicos de dispersão (*fan-out*) seguidos de concentração (*fan-in*) de fluxos, os quais evidenciam a necessidade de modelar as relações no nível de entidades para neutralizar a fragmentação em contas isoladas.

2.2 Métricas de Avaliação

A avaliação de modelos preditivos no contexto de *Anti-Money Laundering* (AML) exige métricas robustas ao desbalanceamento extremo de classes, uma vez que a proporção de transações ilícitas é tipicamente inferior a 1% do volume total (SHUKLA; JAISWAL; PARMAR, 2025).

2.2.1 Matriz de Confusão

Em problemas de classificação binária, cada entidade é rotulada como fraude (classe positiva) ou não fraude (classe negativa) (BISHOP, 2006). A partir das previsões do modelo, obtêm-se quatro resultados possíveis que compõem a matriz de confusão (FAWCETT, 2006):

- *True Positive* (TP): a entidade era fraudulenta e foi corretamente classificada;
- *True Negative* (TN): a entidade não era fraudulenta e foi corretamente classificada;
- *False Positive* (FP): a entidade não era fraudulenta, mas o modelo gerou um alerta falso;
- *False Negative* (FN): a entidade era fraudulenta e não foi detectada.

2.2.2 Métricas de Desempenho e o Problema do Desbalanceamento

O *Recall* (Sensibilidade ou Taxa de Verdadeiros Positivos) mede a capacidade do modelo de identificar corretamente as entidades pertencentes à classe positiva, indicando a proporção de fraudadores reais detectados em relação ao total de fraudes existentes:

$$\text{Recall} = \text{TPR} = \frac{TP}{TP + FN} \tag{1}$$

A *Precision* (Precisão) avalia a exatidão das notificações emitidas pelo sistema, correspondendo à proporção de alertas de fraude que eram verídicos:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{2}$$

O *F1-score* consolida ambas as métricas através de sua média harmônica, oferecendo uma medida única de equilíbrio entre a taxa de captura de fraudes e a taxa de acerto dos alertas gerados (ALARAB; PRAKOONWIT; NACER, 2020):

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{3}$$

Embora a *Accuracy* (Acurácia) meça a proporção global de predições corretas em relação ao total de instâncias ($\frac{TP+TN}{TP+TN+FP+FN}$), sua aplicação direta em cenários de desbalanceamento severo é inadequada. Em bases onde fraudes representam menos de 1% das observações, um classificador ingênuo que rotule todos os exemplos como não fraudulentos atingirá mais de 99% de acurácia, falhando integralmente no objetivo prático de identificação de ilícitos (VASSALLO; VELLA; ELLUL, 2021).

Por essa razão, a literatura de *Anti-Money Laundering* privilegia métricas que avaliam o poder de separação entre classes em diferentes limiares operacionais:

2.2.2.1 Área sob a Curva ROC (ROC-AUC)

A métrica *ROC-AUC* (*Receiver Operating Characteristic - Area Under the Curve*) quantifica a capacidade do modelo de discriminar as classes em todos os possíveis limiares de decisão $\tau \in [0, 1]$ (FAWCETT, 2006). A curva ROC relaciona a Taxa de Verdadeiros Positivos ($\text{TPR}(\tau)$) com a Taxa de Falsos Positivos ($\text{FPR}(\tau) = \frac{FP(\tau)}{FP(\tau)+TN(\tau)}$):

$$\text{ROC-AUC} = \int_0^1 \text{TPR}(\tau)\, d(\text{FPR}(\tau)) \tag{4}$$

O valor de ROC-AUC varia no intervalo $[0{,}5; 1{,}0]$, onde 0,5 representa o desempenho de um classificador aleatório e 1,0 indica a separação perfeita entre as classes.

2.2.2.2 Área sob a Curva Precisão-Recall (AUPRC)

Embora amplamente empregada, a ROC-AUC apresenta uma limitação conceitual importante sob desbalanceamento severo: o cálculo da taxa de falsos positivos (FPR) inclui a quantidade total de verdadeiros negativos (TN) em seu denominador. Dado que $TN \gg FP$ na detecção de fraudes financeiras, mesmo um volume expressivo de falsos positivos (FP) resulta em um FPR numericamente reduzido, conferindo uma impressão excessivamente otimista do poder discriminativo do classificador.

Para contornar essa distorção, a literatura recomenda a *AUPRC* (*Area Under the Precision-Recall Curve*) como métrica de referência para problemas com classes altamente desbalanceadas (LIU et al., 2022). A curva Precisão-Recall desconsidera os verdadeiros negativos (TN), concentrando-se estritamente na relação entre a exatidão dos alertas e a cobertura das fraudes. Matematicamente, a AUPRC corresponde à integral da função de precisão em relação ao *recall* $r \in [0, 1]$, sendo estimada numericamente pela Precisão Média (*Average Precision*):

$$\text{AUPRC} = \int_0^1 \text{Precision}(r)\, dr \approx \sum_{k=1}^{N} \Big(\text{Recall}(k) - \text{Recall}(k-1)\Big) \cdot \text{Precision}(k) \tag{5}$$

onde $\text{Precision}(k)$ e $\text{Recall}(k)$ representam a precisão e o *recall* obtidos no k-ésimo limiar de probabilidade ordenado. Em contrapartida à ROC-AUC, a linha de base aleatória da AUPRC corresponde à proporção real de exemplos positivos na base de dados (da ordem de 1%), de modo que qualquer incremento nessa métrica reflete um ganho concreto na

detecção da classe minoritária.

2.2.2.3 Precisão nos Primeiros k Alertas (Precision@k)

Em ambientes operacionais de *compliance*, os analistas humanos possuem capacidade finita de investigação diária. A métrica operacional Precision@k avalia a fração de fraudes reais identificadas entre os k primeiros alertas com maior probabilidade estimada pelo modelo preditivo (KARIM et al., 2024):

$$\text{Precision@}k = \frac{\sum_{i=1}^{k} y_{(i)}}{k} \tag{6}$$

onde $y_{(i)} \in \{0, 1\}$ indica a classe real da i-ésima entidade ranqueada pelo modelo em ordem decrescente de probabilidade. Essa medida quantifica a eficiência imediata dos alertas prioritários entregues à equipe de auditoria.

2.3 **Teoria dos Grafos**

A Teoria dos Grafos fornece ferramentas matemáticas capazes de modelar interações do mundo real no formato de vértices e arestas (BARABÁSI, 2016). No contexto de transações financeiras, as interações não ocorrem como eventos estáticos e isolados, mas sim como fluxos paralelos que variam no tempo. Por isso, a rede é modelada como um grafo direcionado, ponderado por múltiplos atributos e subdividido em janelas temporais (OLIVEIRA; SANT'ANNA; FERREIRA, 2025).

Formalmente, define-se este grafo como $G = (V, E)$, onde V representa o conjunto de vértices (entidades ou contas bancárias) e E representa o conjunto de arestas direcionadas (fluxos financeiros agregados).

Diferentemente de abordagens tradicionais que utilizam um único peso ou transações individuais, a agregação das transações entre duas entidades u e v dentro de uma janela temporal resulta em uma aresta direcionada $e = (u, v) \in E$ que possui dois atributos quantitativos extraídos na etapa de consolidação dos dados:

- w_{vol}: o volume financeiro transferido do vértice de origem u para o vértice de destino v no período.
- w_{count}: a quantidade de transações realizadas de u para v no período.

A representação de múltiplos pesos nas arestas permite a extração de métricas de centralidade relacionadas à diferentes comportamentos. Neste trabalho, algoritmos como o *PageRank* são calculados em múltiplas formulações independentes, utilizando tanto a

matriz de adjacência ponderada pelo volume (w_{vol}) quanto a ponderada pela frequência transacional (w_{count}). Dessa forma, o modelo identifica não apenas a concentração de grandes volumes de dinheiro, mas também comportamentos de dispersão e estruturação repetitiva (como o *smurfing*), que muitas vezes usa valores menores, mas um número alto de operações (VILELLA et al., 2025).

2.3.1 Grafos Temporais

Em modelagem preditiva, o vazamento de dados (*data leakage*) ocorre quando informações externas ao conjunto de treino, em especial eventos futuros que não estariam disponíveis no momento real da inferência (*look-ahead bias*), são incorporadas inadvertidamente ao modelo ou à engenharia de atributos, gerando métricas de desempenho infladas e irrealistas. No contexto de transações financeiras, a análise baseada em um grafo puramente estático (que consolida todo o histórico em uma única topologia atemporal) introduz *data leakage*, pois permite que fluxos de capital futuros contaminem as propriedades estruturais calculadas para eventos passados (SIZAN et al., 2025).

Para assegurar a causalidade cronológica e reproduzir as restrições informacionais de um ambiente de produção real, a rede transacional deve ser formulada como um grafo temporal dinâmico. Matematicamente, a rede temporal é decomposta em uma sequência de grafos instantâneos (denominados *snapshots*) $G = \{G_1, G_2, \ldots, G_T\}$. Um *snapshot* $G_i = (V_i, E_i)$ representa o estado da rede restrito a um intervalo temporal delimitado por uma janela deslizante (*sliding window*) de duração Δt, a qual avança ao longo do tempo com um passo predefinido (*stride*). Dessa forma, a extração de métricas topológicas para avaliar um vértice no instante i restringe-se exclusivamente às arestas E_i registradas dentro daquela janela temporal específica, impedindo qualquer contaminação por dados futuros.

2.3.2 Atributos Topológicos

A topologia local e global da rede fornece sinais preditivos estruturais que não podem ser descobertos quando os vértices são analisados de forma isolada. Os atributos extraídos dividem-se em três categorias principais:

2.3.2.1 Métricas de Centralidade e Coesão

As métricas de centralidade quantificam a importância ou influência de um vértice na rede, enquanto as de coesão avaliam seu aninhamento estrutural.

- **Grau (*Degree*):** Dividido em grau de entrada (*in-degree*) e de saída (*out-degree*), ele mede o número de conexões distintas de um nó. Matematicamente, dado a matriz de adjacência A do grafo, os graus de um vértice i são definidos como:

$$k_i^{in} = \sum_{j \in V} A_{ji}, \quad k_i^{out} = \sum_{j \in V} A_{ij} \tag{7}$$

  Contas utilizadas como vértices de passagem ou que possuem uma concentração alta de fundos ilícitos tendem a exibir graus mais altos.

- **Algoritmo HITS (*Hyperlink-Induced Topic Search*):** Atribui a cada vértice uma pontuação de *Hub* (h) e uma pontuação de *Authority* (a) (EL-KILANY; AYOUB; KADI, 2024). Estas pontuações são atualizadas iterativamente através da relação mutuamente recursiva:

$$h(u) = \sum_{v \in N_{out}(u)} a(v), \quad a(v) = \sum_{u \in N_{in}(v)} h(u) \tag{8}$$

  onde $N_{out}(u)$ e $N_{in}(v)$ representam os conjuntos de vizinhos de saída de u e de entrada de v, respectivamente (KLEINBERG, 1999).

- **Centralidade de Intermediação (*Betweenness Centrality*):** Mede a frequência com que um vértice aparece nos caminhos mais curtos entre outros pares de nós. A centralidade do vértice v é dada por:

$$C_B(v) = \sum_{s \neq v \neq t \in V} \frac{\sigma_{st}(v)}{\sigma_{st}} \tag{9}$$

  Onde σ_{st} é o número total de caminhos mais curtos de s para t, e $\sigma_{st}(v)$ é o número desses caminhos que passam obrigatoriamente por v. Na lavagem de dinheiro, contas de ofuscação atuam como pontes entre diferentes aglomerados da rede (FREEMAN, 1977).

- ***PageRank* de Múltiplas Profundidades:** Processado com diferentes fatores de amortecimento (α). A pontuação de um vértice u é calculada iterativamente por:

$$PR(u) = \frac{1-\alpha}{N} + \alpha \sum_{v \in B_u} \frac{PR(v)}{L(v)} \tag{10}$$

Sendo N o número total de vértices, B_u o conjunto de vértices que apontam para u, e $L(v)$ o número de links de saída do vértice v. A formulação com $\alpha = 0{,}85$ (*deep*) permite ao algoritmo encontrar padrões mais longos na rede, enquanto $\alpha = 0{,}75$ (*shallow*) foca na influência local, otimizando a detecção de anéis de lavagem curtos e rápidos (PAGE et al., 1999).

- **Decomposição *K-Core*:** Avalia a profundidade de aninhamento de uma conta na rede (SHIN; ELIASSI-RAD; FALOUTSOS, 2016; SHIN; ELIASSI-RAD; FALOUTSOS, 2017; CONTE; RUCCI, 2024). Dado um grafo $G = (V, E)$, um subgrafo induzido $H = (V_k, E_k)$ é definido como um *k-core* se for o subgrafo maximal onde o grau de todo vértice $v \in V_k$, restrito a H, é maior ou igual a k:

$$\forall v \in V_k, \quad d_H(v) \geq k \tag{11}$$

A métrica individual extraída para o modelo preditivo é o valor de *coreness* (ou número *core*) de um vértice, denotado por $c(v)$. Este valor representa o grau máximo k para o qual o vértice v ainda pertence a um *k-core*:

$$c(v) = \max\{k \mid v \in V_k\} \tag{12}$$

Vértices com altos valores de $c(v)$ pertencem ao núcleo denso e estruturalmente coeso do grafo. No contexto financeiro, isso frequentemente está associado a contas controladoras que orquestram e centralizam a fraude, sendo muito mais difíceis de desmantelar do que contas de periferia.

2.3.2.2 Detecção de Comunidades

A detecção de comunidades particiona o grafo em subconjuntos de vértices que estão conectados de forma densa internamente e conectados de forma esparsa com o restante da rede (LIU; CHENG; ZHANG, 2019).

- **Algoritmo Leiden:** Utilizado pela sua eficiência e garantia de conectividade interna. O algoritmo busca particionar a rede de modo a maximizar a métrica de modularidade (Q), proposta originalmente por Newman e Girvan (2004), que compara a densidade de arestas dentro das comunidades com a densidade esperada em um grafo aleatório:

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j) \tag{13}$$

Onde A_{ij} representa o peso da aresta entre i e j, k_i é o grau do vértice i, m é a soma

de todos os pesos das arestas e a função indicadora $\delta(c_i, c_j)$ assume valor 1 se i e j pertencem à mesma comunidade e 0 caso contrário. Fundamentalmente, a modularidade das macro e microcomunidades quantifica o quão isolado e compartimentado está um anel financeiro ilícito em relação à economia lícita adjacente.

2.3.2.3 Padrões de Vizinhança e *Motifs*

A extração da topologia de entorno e de subgrafos frequentes (*motifs*) captura a mecânica exata das tipologias de fraude (AKOGLU; MCGLOHON; FALOUTSOS, 2010; MITCHELL; AGRAWAL; PARKER, 2019).

- **Atributos de *Egonet* (Rede de Ego):** Avaliam a vizinhança imediata (1-hop) do vértice. A extração da densidade da egorrede, quantidade de nós, arestas e peso total consolidado medem a coesão local ao redor da entidade. O coeficiente de agrupamento (*local clustering coefficient*) e a contagem de triângulos refinam essa análise validando a interconectividade dos vizinhos.

- **Padrões Direcionais e *Motifs* Complexos:** A contagem de estruturas simples de dispersão (*fan-out*) e concentração (*fan-in*) é expandida para *motifs* compostos, como o *scatter-gather* e o *gather-scatter*. Estas topologias são as representações matemáticas exatas das fases de pulverização (*layering*) e integração (*integration*) de recursos (WEBER et al., 2019). A contagem de ciclos (*cycle count*) mapeia as trajetórias circulares utilizadas para criar a ilusão de atividade econômica legítima.

- **Agregação de Vizinhança e Dinâmica Temporal:** Sinais de fraude propagam-se topologicamente. O comportamento dos vizinhos (volume médio e máximo transferido por eles) sinaliza o destino do capital pós-transferência. Adicionalmente, *motifs* temporais (*temporal fan-out* e *temporal fan-in*) medem a estruturação de fluxos de forma cronológica, capturando operações que ocorrem em frações de tempo curtas.

3 METODOLOGIA E DESENVOLVIMENTO

"Simplicity is prerequisite for reliability."
Edsger W. Dijkstra

Este capítulo detalha a metodologia proposta para investigar e quantificar o impacto da adição de variáveis topológicas na detecção de esquemas de lavagem de dinheiro. O desenvolvimento do trabalho é estruturado de forma a replicar os desafios de um ambiente de *compliance* do mundo real, considerando a avaliação cronológica e eficiência computacional.

3.1 Base de Dados

Para o treinamento e a validação da arquitetura proposta, este estudo utiliza o *dataset* sintético AMLworld (ALTMAN et al., 2023). O conjunto de dados foi desenvolvido especificamente para pesquisas em detecção de lavagem de dinheiro e disponibilizado publicamente pelos autores sob a licença Community Data License Agreement – Sharing 1.0 (CDLA-Sharing-1.0), uma licença aberta destinada ao compartilhamento e à reutilização de dados. A escolha por uma base de dados sintética decorre, entre outros fatores, das restrições de privacidade e confidencialidade associadas ao acesso a dados financeiros reais. Além disso, há o problema de que parte das fraudes que ocorrem no mundo real passam desapercebidas pelas autoridades, o que torna as bases de dados baseadas em transações reais deficitárias. O AMLworld foi projetado especificamente para simular padrões de lavagem de dinheiro em larga escala e oferecer rótulos confiáveis para transações lícitas e ilícitas, o que viabiliza o treinamento supervisionado.

A base de dados oferece, ao todo, seis variações que combinam escala (*Small*, *Medium* e *Large*) e nível de atividade ilícita (HI: *High Illicit*; LI: *Low Illicit*), conforme apresentado na Tabela 1.

Tabela 1 – Resumo das variações do *dataset* AMLworld

Métrica	**HI Small**	**LI Small**	**HI Medium**	**LI Medium**	**HI Large**	**LI Large**
Intervalo de datas (2022)	Sep 1–10	Sep 1–10	Sep 1–16	Sep 1–16	Aug 1–Nov 5	Aug 1–Nov 5
Dias cobertos	10	10	16	16	97	97
Contas bancárias	515K	705K	2,077K	2,028K	2,116K	2,064K
Transações	5M	7M	32M	31M	180M	176M
Transações de lavagem	5,1K	4,0K	35K	16K	223K	100K
Taxa de lavagem (1 em N transações)	981	1,942	905	1,948	807	1,750
Tamanho (GB)	0,5	0,6	3	3	17	16

Fonte: Adaptado de Altman et al. (2023).

Neste trabalho, foram utilizados os *datasets* HI Small e HI Medium.

3.1.1 Pré-processamento e Padronização dos Dados

Devido ao volume massivo de registros gerados pelas variações do *dataset* AMLworld (alcançando até 180 milhões de transações na variação *Large*), o tratamento da base bruta exigiu uma etapa de pré-processamento e engenharia de dados.

A leitura do arquivo original em formato de texto (*CSV*) foi implementada em blocos de 3 milhões de linhas utilizando a biblioteca Pandas em Python (versão 3.12)[1]. Durante a iteração, os cabeçalhos foram padronizados, as datas convertidas para o formato ISO 8601 e, para garantir viabilidade computacional no processamento subsequente, os dados foram persistidos no formato colunar Apache Parquet [2]. Esta conversão reduziu drasticamente o espaço de armazenamento e otimizou a velocidade de leitura (*I/O*) nas etapas de agregação.

Adicionalmente, o *dataset* simula um ambiente global, contendo transações realizadas em 14 moedas fiduciárias distintas (incluindo Euro, Libra, Real e Iene), bem como em criptomoedas (Bitcoin). A modelagem de um grafo financeiro ponderado exige que todas as arestas utilizem a mesma escala de grandeza. Caso contrário, a soma direta de valores nominais distorceria os algoritmos de centralidade (OLIVEIRA; SANT'ANNA; FERREIRA, 2025).

Para resolver este problema, desenvolveu-se uma etapa de padronização monetária. Utilizando a API do *Yahoo Finance* (`yfinance`), foram extraídas as taxas de câmbio diárias de fechamento em relação ao Dólar Americano (USD) para todo o período da simulação do *dataset* (agosto a novembro de 2022). Esta tabela de câmbio foi salva de forma independente e utilizada posteriormente para calibrar o peso financeiro (w_{vol}) de cada aresta com base na data exata da transação original. Com isso, todas as transações foram convertidas para USD utilizando a taxa de câmbio vigente no dia da operação.

3.2 Modelagem da Janela Deslizante e Agregação de Arestas

Para mitigar o risco de vazamento de dados (*data leakage*) e preservar a causalidade estrita dos eventos financeiros (SIZAN et al., 2025), o fluxo de transações do *dataset* AMLworld foi processado cronologicamente como um grafo temporal.

A extração das janelas cronológicas (*snapshots*) e a agregação do grafo foram implementadas utilizando o sistema de gerenciamento de banco de dados analítico em memória DuckDB (RAASVELDT; MÜHLEISEN, 2019). A adoção do DuckDB justifica-se pela

[1] Python Software Foundation. Disponível em: https://www.python.org/.

[2] Apache Parquet. Disponível em: https://parquet.apache.org/.

sua alta eficiência de *I/O* e otimização *multithreading* (configurado para 8 *threads* e limite de memória de 6 GB) ao processar os milhões de registros transacionais armazenados no formato colunar Apache Parquet.

A definição do tamanho da janela deslizante (Δt) e do passo temporal (*stride*) baseou-se em uma etapa de otimização empírica. Foram testadas diferentes configurações com o objetivo de maximizar o desempenho preditivo (métricas de avaliação extraídas do modelo) garantindo, simultaneamente, a viabilidade computacional do processamento das métricas topológicas em um ambiente com recursos limitados de memória (8 GB de RAM).

Dentro de cada janela de 3 dias, as transações individuais (multiarestas) foram agregadas. É importante ressaltar que os vértices do grafo (V) foram modelados para representar **entidades financeiras** (indivíduos ou empresas) e não contas bancárias isoladas. Essa etapa de mapeamento, realizada com auxílio da tabela de entidades do *dataset*, justifica-se pelo fato de que agentes ilícitos frequentemente utilizam múltiplas contas bancárias para praticar a estruturação de transações (*smurfing*, conforme detalhado na Seção 2.1) e simular fluxos operacionais legítimos. Ao consolidar o grafo no nível de entidades, evidencia-se o fluxo real de capital, neutralizando as tentativas de ofuscação e fragmentação de recursos entre diferentes contas bancárias controladas por uma mesma entidade.

Dessa forma, as transações ocorridas entre uma entidade de origem u e uma entidade de destino v foram consolidadas, resultando em um grafo direcionado simples onde cada aresta $e = (u, v)$ resume o fluxo financeiro do período.

Essa etapa de simplificação estrutural é necessária devido ao fato de algoritmos como o *PageRank*, *Betweenness Centrality* e os algoritmos de detecção de comunidades exigirem uma matriz de adjacência simples ponderada, não operando nativamente sobre multigrafos (BAIGABYL; NUGUMANOVA; SODNOMOVA, 2025). Consolidando multiarestas em uma única aresta direcional, é possível preservar a magnitude e a frequência do fluxo financeiro por meio dos atributos de peso, o que torna viável o processamento matemático da rede (VILELLA et al., 2025).

Durante este processo de agrupamento via SQL, os seguintes atributos consolidados de aresta foram extraídos:

- **Volume Agregado em USD (w_{vol}):** Utilizando a tabela histórica de taxas de câmbio, combinando a moeda de pagamento e a data exata da transação original.
- **Frequência por Formato de Pagamento (w_{count}):** Além do número absoluto de transações consolidadas, a agregação também identifica a volumetria pela contagem de meios de pagamento específicos utilizados na janela (e.g., *cash*, *bitcoin*, *cheque*, *credit card* e *ACH*).

Esta agregação gerou a matriz de adjacência ponderada final do *snapshot*, a qual

serviu como estrutura base para a extração computacional das *features* topológicas na etapa subsequente.

3.3 Engenharia de *Features* Topológicas

A extração de atributos topológicos foi aplicada individualmente a cada um dos grafos instantâneos (G_i) gerados na etapa anterior. Para viabilizar o processamento em tempo hábil das centenas de milhares de transações por janela, a rotina de extração foi implementada com suporte a multiprocessamento através da biblioteca `concurrent.futures` do Python, distribuindo a carga computacional das janelas temporais de forma paralela. A base principal para o cálculo das métricas foi a biblioteca `NetworkX` (HAGBERG; SCHULT; SWART, 2008), com exceção da detecção de comunidades via algoritmo de Leiden, a qual foi executada por meio da biblioteca `igraph` (TRAAG; WALTMAN; ECK, 2019).

Além das heurísticas de vértice pré-calculadas na rotina de banco de dados, como uso de moedas em espécie, *bitcoin* e contagem direcional temporal, as rotinas em Python extraíram os seguintes conjuntos de atributos estruturais:

3.3.1 Métricas de Centralidade e Coesão

O cálculo exato de algumas métricas de centralidade em grafos esparsos e de grande escala possui uma complexidade de tempo proibitiva. Portanto, foram adotadas otimizações e parametrizações específicas para o ambiente de *Big Data*:

- **Centralidade de Intermediação (*Betweenness*):** O cálculo exato dessa métrica exige encontrar os caminhos mais curtos entre todos os pares de nós ($O(|V||E|)$), o que é inviável em redes de grande escala. Para contornar esse custo computacional, utilizou-se uma aproximação por amostragem (RIONDATO; KORNAROPOULOS, 2014), calculando os caminhos mínimos a partir de $k = 80$ nós sentinelas. Fixou-se a semente aleatória ($seed = 42$) para garantir a reprodutibilidade dos experimentos e a consistência da amostragem entre diferentes janelas temporais, equilibrando tempo de execução e precisão.

- ***PageRank*:** A fim de capturar diferentes dinâmicas de circulação financeira, o *PageRank* foi instanciado em quatro variações. Para abranger múltiplas escalas de profundidade na rede, adotaram-se dois fatores de amortecimento (*damping factor*): o valor padrão $\alpha = 0{,}85$, cuja probabilidade de continuidade propaga influência por caminhos mais longos (capturando cadeias extensas de estratificação financeira), e

um valor reduzido $\alpha = 0{,}75$, que penaliza trajetórias longas e confina o fluxo à vizinhança imediata (ideal para identificar anéis locais e esquemas rápidos de estruturação/*smurfing*). Ambas as formulações foram calculadas sob duas perspectivas de peso: ponderadas pelo volume financeiro transacionado (w_{vol}) e pela frequência de transações (w_{count}), permitindo distinguir a concentração de capital de fluxos repetitivos. O critério de convergência foi fixado em 100 iterações.

- **Algoritmo HITS:** O processamento das pontuações de *Hub* e *Authority* foi parametrizado com um limite máximo de 500 iterações ($max_iter = 500$), com o objetivo de garantir a convergência mesmo em janelas temporais de com alta densidade de vértices e arestas.

- **Decomposição *K-Core*:** Devido à exigência topológica do algoritmo, o grafo direcionado ponderado foi primeiramente convertido para uma projeção simples não-direcionada e sem auto-laços (*self-loops*) (SHIN; ELIASSI-RAD; FALOUTSOS, 2017). A partir dessa projeção, extraiu-se o valor de *coreness* máximo atingido por cada entidade na referida janela temporal.

3.3.2 Detecção de Comunidades (Leiden)

Embora o `NetworkX` possua ampla gama de algoritmos de grafos, ele apresenta gargalos de performance para detecção de comunidades. Por isso, o grafo foi convertido para a estrutura da biblioteca `igraph`, permitindo a aplicação da biblioteca `leidenalg` (TRAAG; WALTMAN; ECK, 2019).

A otimização de modularidade foi realizada empregando o modelo *RBConfigurationVertexPartition*. Algoritmos de maximização de modularidade sofrem com o problema do "limite de resolução"(*resolution limit*), uma falha topológica na qual pequenas comunidades densas acabam sendo aglomeradas em grupos maiores, ocultando anomalias locais.

Para contornar este problema e garantir que o modelo de *Machine Learning* capture tipologias de lavagem de dinheiro em diferentes escalas, o algoritmo de Leiden foi executado em duas resoluções distintas:

- **Macro-resolução ($\gamma = 1{,}0$):** Representa a formulação de modularidade padrão. O algoritmo agrupa vértices de forma mais permissiva, identificando grandes agrupamentos e a estrutura global da rede. No contexto de prevenção à fraude, esta escala mapeia grandes redes de cooperação, revelando se a entidade pertence a um ecossistema grande.

- **Micro-resolução ($\gamma = 2{,}0$):** Aumentar o parâmetro de resolução penaliza a união de vértices. Isso faz com que o algoritmo extraia comunidades menores, porém com

conectividade interna alta. Para o domínio de *AML*, essa escala é importante para isolar anéis fechados de ofuscação, detectar *smurfing* e mapear empresas de fachada que transferem recursos intensamente entre si em curtos períodos de tempo.

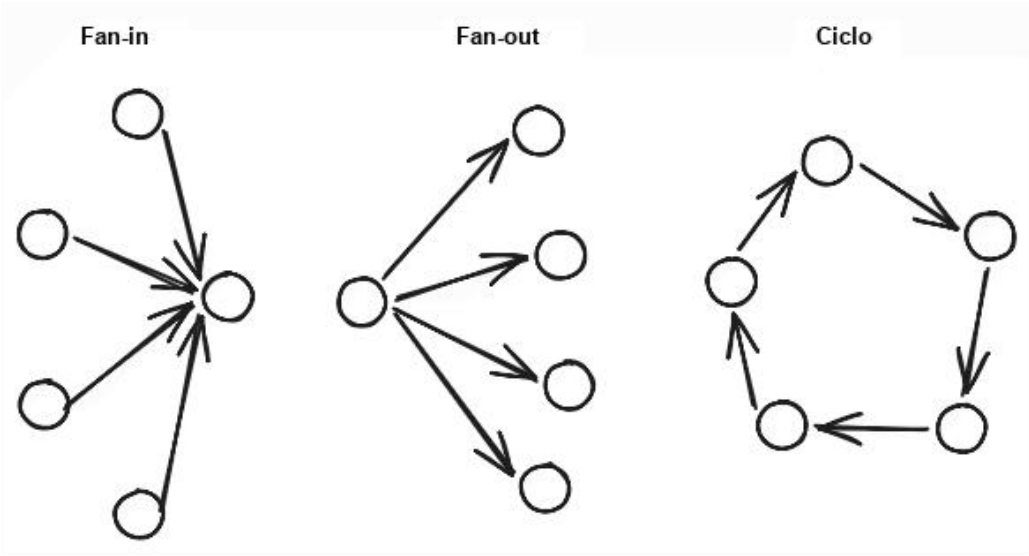
Para cada resolução, extraiu-se o tamanho da comunidade (*size*) na qual o vértice foi inserido e a pontuação de modularidade local. Assim, esses dados foram adicionados à tabela de *features* da entidade correspondente. Isso permite compreender se um usuário atua como parte de um grupo criminoso grande ou pequeno.

3.3.3 Padrões de Vizinhança, Agregação e *Motifs*

Os padrões comportamentais de vizinhança foram extraídos para mapear a estrutura no entorno das entidades financeiras (DONG et al., 2025).

- ***Egonets* e Coesão Local:** Para cada vértice, gerou-se o seu subgrafo de raio 1 (*ego graph*). A partir dele, calculou-se a densidade local, a contagem de vértices periféricos e o volume de dinheiro transferido. Em paralelo, calculou-se o coeficiente de agrupamento local (*local clustering coefficient*) utilizando os pesos financeiros, além da contagem de triângulos baseada na projeção não-direcionada da rede.
- **Agregação de Sucessores:** Como forma de avaliar o risco de pulverização, extraiu-se a volumetria enviada aos sucessores de cada nó. Foram calculados o grau médio da vizinhança e os volumes médio e máximo enviados aos nós destinos no *snapshot*.
- **Mapeamento de Padrões Topológicos:** Uma função de busca de subgrafos isomorfos foi implementada para quantificar padrões conhecidos de lavagem de dinheiro presentes no *dataset*, ilustrados esquematicamente na Figura 2. O limiar para detecção de estruturas de dispersão e concentração (*fan-out* e *fan-in*) foi estipulado em $k \geq 6$ vizinhos. Para focar a busca no escopo correto, o grau máximo analisado foi restrito a 16 conexões, uma vez que este foi o limite máximo documentado para os padrões sintéticos de fraude injetados no *dataset* AMLworld (ALTMAN et al., 2023), atuando também como uma forma de economizar recursos computacionais. Com base nessa filtragem, calcularam-se as ocorrências de *fan-out* e *fan-in*. Adicionalmente, buscou-se a ocorrência de ciclos simples fechados limitados a até 6 saltos de distância ($cycle_bound = 6$). Como o problema algorítmico de enumeração de ciclos em grafos direcionados possui alta complexidade computacional, podendo crescer exponencialmente em redes densas, aplicou-se uma trava de segurança limitando a extração a um máximo de 2.000 ciclos por nó ($max_cycles = 2000$), garantindo a viabilidade do processamento em larga escala.

Figura 2 – Fan-in, Fan-out e Ciclo Direcionado em Grafos Financeiros



Fonte: Elaborado pelo autor.

Ao término da extração das *features*, as tabelas tabulares isoladas de cada *chunk* foram concatenadas pelo DuckDB, construindo o *dataset* final (`sliding_window_features.parquet`) que servirá de matriz de entrada (X) para o modelo preditivo e um arquivo com métricas (`sliding_window_metrics.parquet`) para cada umas das *features* extraídas.

3.4 **Arquitetura Preditiva e Calibração de Limiar com XGBoost**

O processo de modelagem preditiva foi desenhado para lidar com os dois maiores desafios na detecção de lavagem de dinheiro: desbalanceamento extremo de classes, onde as fraudes representam uma fração minúscula do volume total, muitas vezes inferior a 0,1%, e a necessidade de minimizar os falsos positivos sem comprometer a descoberta de ilícitos reais. Para tanto, adotou-se o algoritmo *eXtreme Gradient Boosting* (XGBoost) (CHEN; GUESTRIN, 2016) com calibração de limiar baseada em busca de maximização de precisão sob restrição de cobertura (*Recall-constrained threshold calibration*) (SHUKLA; JAISWAL; PARMAR, 2025). O algoritmo busca o limiar que maximiza a precisão garantindo um Recall mínimo de 85% para a janela de validação.

3.4.1 Divisão Cronológica dos Dados (*Forward-Chaining*)

Para preservar a causalidade temporal estrita e eliminar o risco de viés de antecipação (*look-ahead bias*) e vazamento de dados (*data leakage*), adotou-se o protocolo

de validação cruzada temporal por encadeamento progressivo (*forward-chaining cross-validation*) (SIZAN et al., 2025). Sob esse arranjo, os *snapshots* temporais do grafo e suas matrizes de atributos correspondentes foram estritamente ordenados no tempo. Esse protocolo metodológico rege tanto o treinamento do classificador XGBoost quanto o particionamento sobre o qual as métricas de desempenho são mensuradas a cada ciclo temporal.

O processo de avaliação opera de forma iterativa por meio de janelas temporais expansivas (*expanding window*). Estabeleceu-se um período mínimo inicial de duas janelas (W_0 e W_1) para compor o histórico de treinamento. A partir da terceira janela ($t \geq 2$), em cada iteração, o modelo utiliza como treino o histórico acumulado de todas as janelas passadas ($W_0, \ldots, W_{t-1}$) e é avaliado de forma cega exclusivamente na janela imediatamente subsequente (W_t).

Para assegurar que a calibração do limiar de decisão (visando ao *Recall* mínimo de 85%) também não incorra em vazamento de dados, o conjunto histórico de treino de cada iteração foi particionado temporalmente em treino interno (80%) e validação interna (20%). O limiar ótimo obtido nessa partição de validação foi então congelado e aplicado à inferência da janela de teste W_t. Essa formulação reproduz fielmente as condições operacionais de uma instituição financeira, onde o motor de *compliance* opera com retreinamento periódico sobre o histórico acumulado e realiza inferências sobre janelas futuras sem qualquer conhecimento prévio dos fluxos transacionais subsequentes.

3.5 Modelos Preditivos e Avaliação de Desempenho

Para garantir que o comportamento real das transações seja preservado, optou-se por não aplicar algoritmos de reamostragem sintética, evitando assim distorções no espaço de dados. Em vez disso, a assimetria do problema é tratada diretamente na função de perda do *Gradient Boosting*. A estrutura experimental compara dois modelos preditivos independentes submetidos à validação temporal *forward-chaining*:

- **Modelo Base (*Baseline*):** O objetivo deste modelo é estabelecer o piso de desempenho preditivo do sistema. Ele é treinado exclusivamente com as *features* tabulares comportamentais e financeiras (e.g., volume de transações, razão de fluxo).
- **Modelo Completo (*Full Model*):** Este classificador ingere o conjunto total de dados enriquecido, unindo as variáveis comportamentais do *Baseline* às *features* topológicas de grafos (como *coreness*, comunidades do algoritmo Leiden, *motifs* direcionais e ciclos). O objetivo é isolar e quantificar o ganho real de informação (LIFT) gerado pela topologia da rede no poder preditivo do sistema.

3.5.1 Ponderação Dinâmica da Função de Perda

Para lidar com o severo desbalanceamento das classes no *dataset*, evitou-se o uso tradicional de subamostragem (*undersampling*), técnica que descarta aleatoriamente registros legítimos para equilibrar a proporção entre as classes, mas acarreta perda de informações valiosas. Em seu lugar, adotou-se a ponderação da função de perda logística do próprio XGBoost (`scale_pos_weight`).

Durante cada iteração da validação temporal, a razão exata de desbalanceamento do conjunto de treino é calculada dinamicamente:

$$scale_pos_weight = \frac{\sum(y_{train} == 0)}{\sum(y_{train} == 1)} \tag{14}$$

Ao injetar este fator diretamente no cálculo do gradiente das árvores de decisão, o algoritmo aumenta severamente a penalidade por cada falso negativo, forçando o modelo a mapear as fronteiras de decisão das transações ilícitas sem destruir a densidade informacional da classe majoritária.

O desempenho do sistema foi mensurado através da métrica Área Sob a Curva de Precisão-Recall (*AUPRC*) e do ranqueamento de *Precision@k* (onde k assume valores fixos de capacidade investigativa diária, como 100, 300 e 500 entidades). O uso destas métricas avalia o modelo com base na efetividade dos primeiros alertas gerados perante um alto índice de desbalanceamento, refletindo de forma realista o ganho de tempo dos analistas de risco (KARIM et al., 2024).

3.5.2 Estudo de Ablação

Para quantificar o impacto da adição das *features* topológicas, implementou-se um estudo de ablação controlado, comparando estatisticamente o desempenho de dois modelos: um modelo de base (*Baseline*) treinado exclusivamente com atributos comportamentais e um modelo completo (*Full Model*) que inclui tanto os atributos comportamentais quanto os topológicos extraídos dos grafos.

O experimento foi conduzido sob validação temporal estrita (*forward-chaining*), na qual cada modelo foi treinado em janelas históricas e avaliado em janelas subsequentes. Para verificar se as diferenças de desempenho entre os conjuntos de *features* foram estatisticamente significativas, aplicou-se o teste t pareado entre as janelas temporais (DIETTERICH, 1998; JAPKOWICZ; SHAH, 2011).

Nesse teste, a hipótese nula (H_0) assume que não há diferença real de desempenho entre as abordagens comparadas (ou seja, a média das diferenças de desempenho entre os modelos ao longo das janelas é igual a zero), enquanto a hipótese alternativa (H_1)

indica que a inclusão das variáveis topológicas gera alteração significativa no resultado. Adotou-se o nível de significância padrão $\alpha = 0{,}05$ (95% de confiança) para a rejeição de H_0. Adicionalmente, resultados com p-valor inferior a $\alpha = 0{,}01$ (99% de confiança) foram sinalizados com asterisco duplo.

4 RESULTADOS E DISCUSSÃO

> "In God we trust. All others must bring data."
>
> *W. Edwards Deming*

Este capítulo apresenta os resultados experimentais obtidos através da aplicação da metodologia descrita no Capítulo 3. A avaliação foi conduzida utilizando dois *datasets* sintéticos do AMLworld: o HI Small, contendo 1.245.666 registros transacionais agregados em 8 janelas temporais com taxa de fraude de 1,15%, e o HI Medium, contendo 7.376.519 registros transacionais com taxa de fraude de 1,35%. Os experimentos em ambos os *datasets* utilizaram processamento através de janelas temporais deslizantes (*forward-chaining*) para preservar a causalidade estrita.

4.1 Desempenho dos Modelos Baseline e Full

A Tabela 2 apresenta o resumo consolidado de desempenho dos dois modelos avaliados em ambos os *datasets*: o modelo de base (*Baseline*), treinado com 21 atributos puramente comportamentais, e o modelo completo (*Full Model*), treinado com 49 atributos (21 comportamentais + 28 topológicos).

4.1.1 Resultados no Dataset HI Small

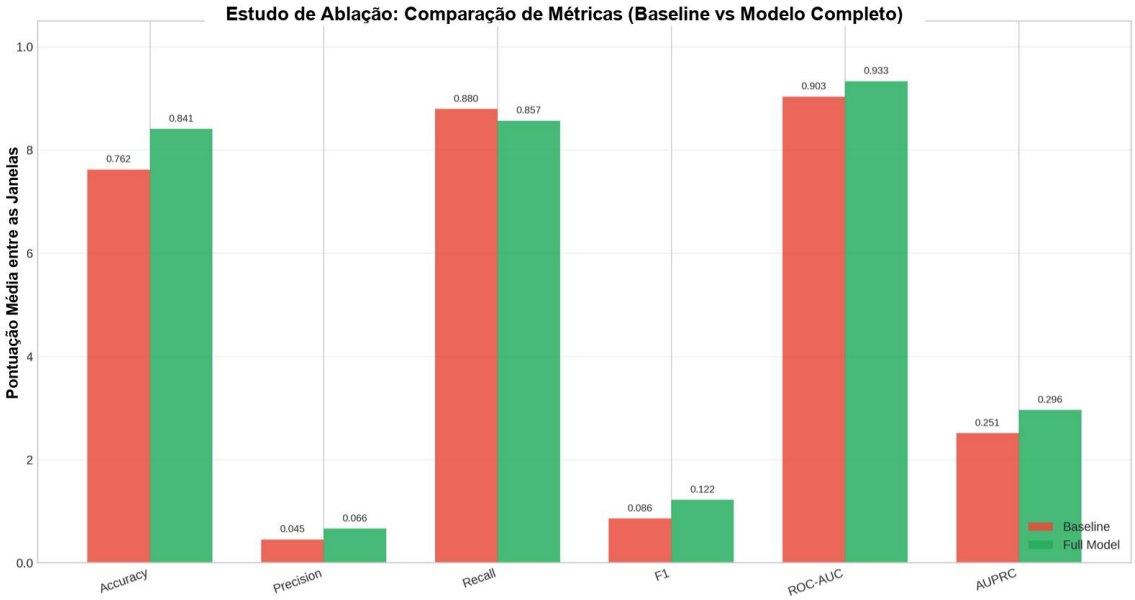
Tabela 2 – Desempenho dos modelos no dataset HI Small

Métrica	**Baseline**	**Full Model**	**Lift**	**Lift (%)**
Acurácia	0,7622	0,8408	0,0786	10,31%
AUPRC	0,2513	0,2965	0,0452	18,00%
ROC-AUC	0,9038	0,9309	0,0271	3,00%
F1-Score	0,0860	0,1220	0,0360	41,86%
Precisão	0,0450	0,0660	0,0210	46,67%
Recall	0,8802	0,8570	−0,0230	−2,61 %
P@100	0,9900	0,9900	0,0000	0,00%
P@200	0,9750	0,9700	−0,0050	−0,51 %
P@300	0,9500	0,9600	0,0100	1,05%
P@500	0,9280	0,9320	0,0040	0,43%

Fonte: Elaborado pelo autor.

Os resultados no HI Small indicam que a adição das *features* topológicas resultou em melhorias substanciais em múltiplas métricas de desempenho, conforme comparado visualmente na Figura 3. O ganho mais expressivo ocorreu na precisão (+46,67%), seguido pelo F1-Score (+41,86%) e pela AUPRC (+18,00%). Esses incrementos são particularmente relevantes no contexto de detecção de fraudes, onde a redução de falsos positivos impacta diretamente a carga de trabalho das equipes de *compliance*.

Figura 3 – Comparação de métricas entre os modelos Baseline e Full Model (HI Small)



Fonte: Elaborado pelo autor.

4.1.2 Resultados no Dataset HI Medium

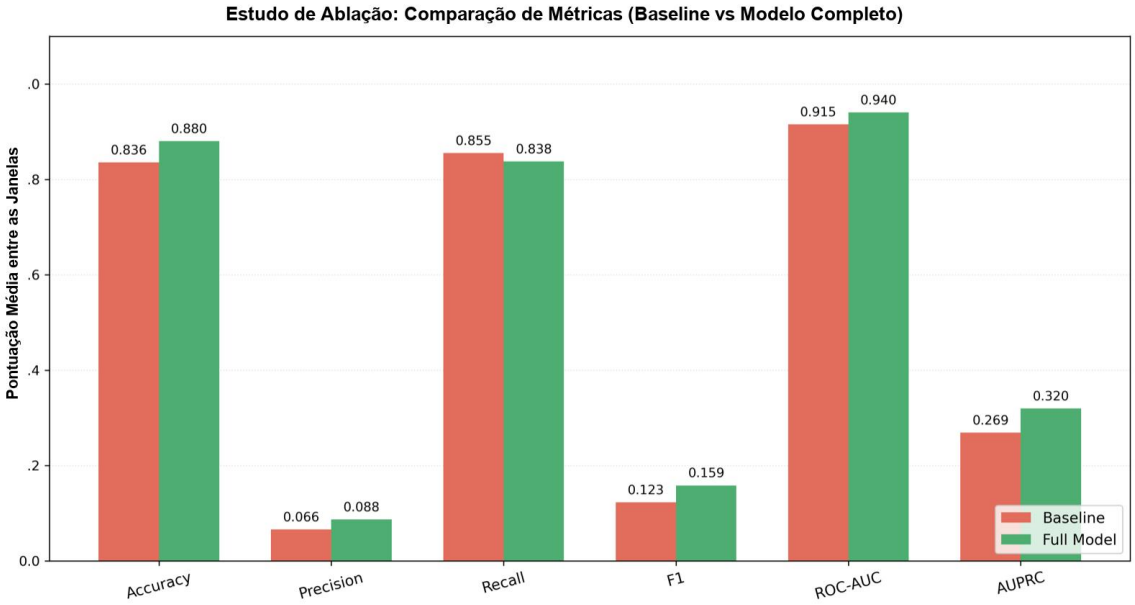
Os resultados no HI Medium, detalhados na Tabela 3 e ilustrados na Figura 4, apresentam um padrão consistente com o observado no HI Small, demonstrando a generalização das contribuições dos atributos topológicos a *datasets* de maior escala. A AUPRC apresenta um ganho (+10,85%) similar ao HI Small (+18,00%), validando que o benefício das *features* topológicas é robusto e não depende apenas da escala do *dataset*. A precisão (+29,83%) também mostra ganho substancial, ainda que ligeiramente inferior ao HI Small, sugerindo um *trade-off* entre complexidade e benefício em *datasets* maiores.

Tabela 3 – Desempenho dos modelos no dataset HI Medium

Métrica	Baseline	Full Model	Lift	Lift (%)
Acurácia	0,8357	0,8803	+0,0446	+5,34%
AUPRC	0,2689	0,3197	+0,0508	+18,88%
ROC-AUC	0,9155	0,9401	+0,0246	+2,69%
F1-Score	0,1229	0,1585	+0,0357	+29,04%
Precisão	0,0662	0,0875	+0,0214	+32,28%
Recall	0,8550	0,8379	-0,0171	-2,00%
P@100	0,9800	1,0000	+0,0200	+2,04%
P@200	0,9850	1,0000	+0,0150	+1,52%
P@300	0,9800	1,0000	+0,0200	+2,04%
P@500	0,9840	1,0000	+0,0160	+1,63%

Fonte: Elaborado pelo autor.

Figura 4 – Comparação de métricas entre os modelos Baseline e Full Model (HI Medium)



Fonte: Elaborado pelo autor.

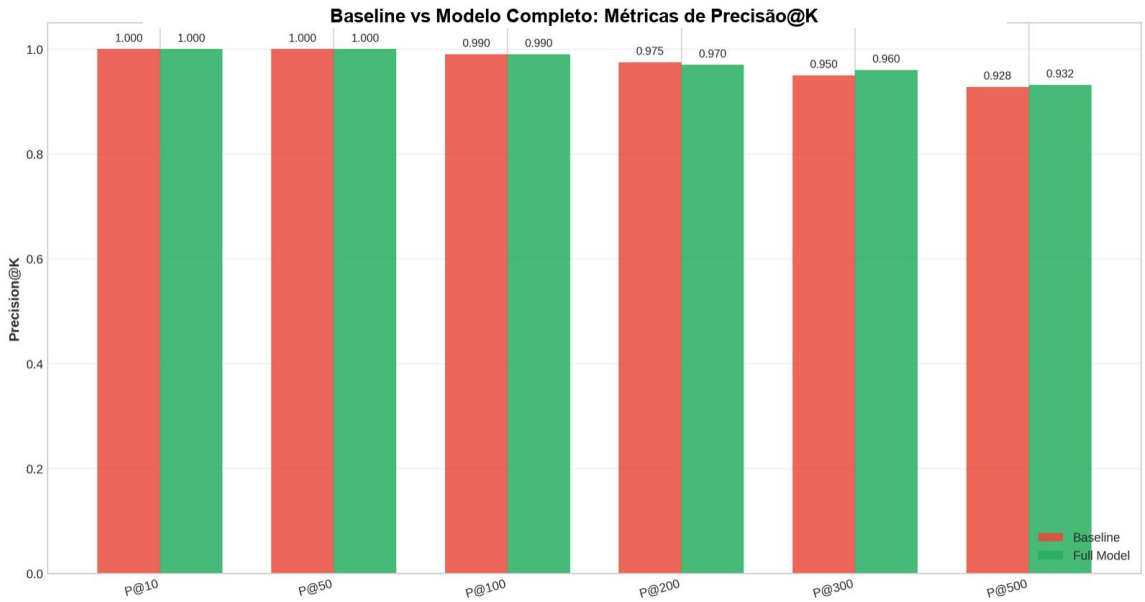
4.1.3 Análise Comparativa Entre Datasets

A comparação entre o HI Small e o HI Medium revela características importantes sobre a escalabilidade da abordagem topológica. Ambos os *datasets* apresentam ganhos de AUPRC praticamente idênticos (+18,00% e +18,88%), o que evidencia que o poder preditivo das variáveis estruturais se mantém estável mesmo com o aumento expressivo no volume de transações, isto é, o sinal capturado pelas propriedades de rede independe da escala da base de dados. Entretanto, o ganho em F1-Score e Precisão é mais pronunciado no HI Small, o que pode estar associado a diferenças nas distribuições de fraude ou na densidade de conexões da rede entre os dois cenários.

4.1.4 Métrica Precision@k e Eficácia Operacional

A métrica *Precision@k*, que avalia a eficácia operacional do sistema ao ranquear as entidades de maior risco, manteve-se alta para ambos os modelos em ambos os *datasets*, conforme demonstrado nas Figuras 5 e 6. Com P@100 próximo de 0,99 no HI Small e variando entre 0,98 e 1,00 no HI Medium, o sistema demonstra alta confiabilidade na priorização de alertas.

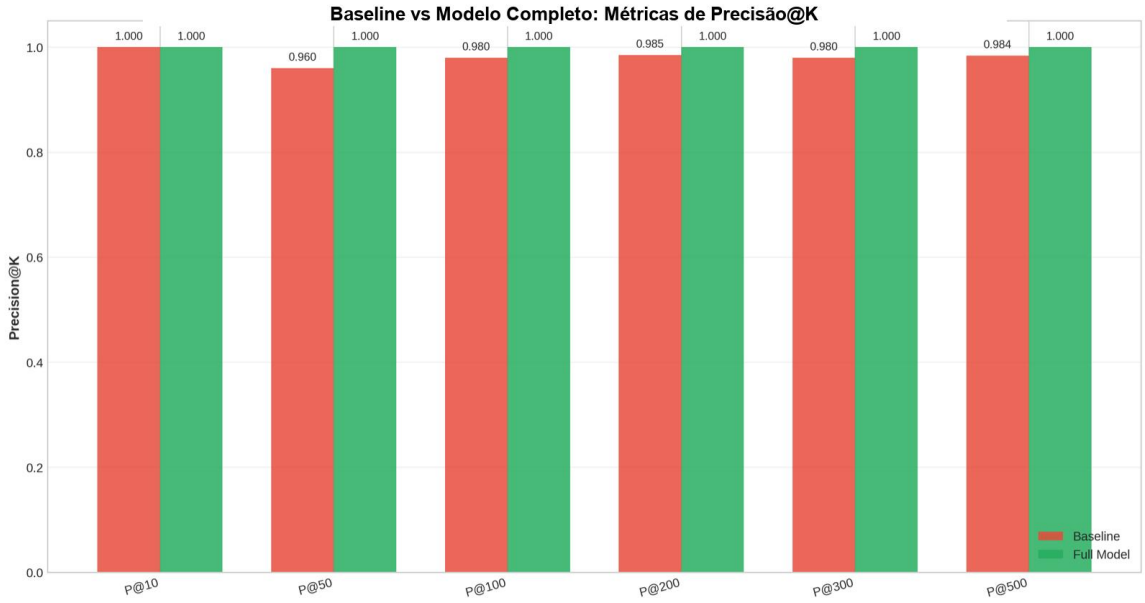
Figura 5 – Comparação de Precision@k entre os modelos Baseline e Full Model (HI Small)



Fonte: Elaborado pelo autor.

Observa-se uma leve redução no *Recall* geral (HI Small: -3,08%, HI Medium: -2,00%), o que indica um *trade-off* esperado: ao refinar a fronteira de decisão para reduzir falsos positivos (aumentando a precisão), o modelo torna-se ligeiramente mais conserva-

Figura 6 – Comparação de Precision@k entre os modelos Baseline e Full Model (HI Medium)



Fonte: Elaborado pelo autor.

dor, deixando de capturar uma pequena fração de fraudes. No entanto, essa perda é compensada pelo ganho substancial em precisão e pela redução da sobrecarga investigativa.

4.1.5 Análise de Desempenho Temporal no HI Small

A Tabela 4 apresenta a comparação detalhada de desempenho entre os modelos *Baseline* e *Full* ao longo das seis janelas de teste do *dataset* HI Small, permitindo avaliar a consistência temporal dos ganhos observados.

Tabela 4 – Comparação de desempenho por janela temporal

Janela	AUPRC (B)	AUPRC (F)	Lift AUPRC	P@100 (B)	P@100 (F)	Lift P@100
2	0,180	0,208	15,5 %	0,82	0,75	−8,5 %
3	0,234	0,293	25,6 %	0,91	0,92	1,1%
4	0,275	0,353	28,2 %	0,96	0,96	0,0%
5	0,352	0,414	17,7 %	0,97	0,98	1,0%
6	0,251	0,239	−4,8 %	0,88	0,83	−5,7 %
7	0,217	0,272	25,8 %	0,90	0,87	−3,3 %
Média	**0,251**	**0,297**	**18,0 %**	**0,907**	**0,885**	**−2,7 %**

Fonte: Elaborado pelo autor.

A análise temporal no HI Small revela que o modelo completo apresentou ganhos positivos de AUPRC em 5 das 6 janelas testadas, com *lifts* variando entre +15,5% e

+28,2%. A exceção ocorreu na janela 6, onde houve uma leve degradação de -4,8%. Essa variação pode estar associada a mudanças na distribuição temporal dos padrões de fraude ou a diferenças na densidade topológica do grafo naquele período específico.

Para as métricas de *Precision@k*, observa-se um padrão mais heterogêneo. Em algumas janelas (especialmente as janelas iniciais), o modelo *Baseline* apresentou desempenho superior, o que sugere que, para os alertas de altíssimo risco (top-100), os atributos comportamentais isolados já forneciam sinais preditivos robustos. No entanto, conforme se expande o horizonte investigativo para P@300 e P@500, o modelo completo recupera vantagem consistente, demonstrando que as *features* topológicas são especialmente úteis para refinar a classificação em níveis intermediários de risco.

4.1.6 Análise de Desempenho Temporal no HI Medium

Para o *dataset* HI Medium, a análise temporal abrange 12 janelas de teste, oferecendo uma perspectiva mais granular da robustez temporal da abordagem topológica. A Tabela 5 apresenta um resumo de 6 janelas selecionadas (as intermediárias), enquanto o padrão completo confirma ganhos positivos de AUPRC em todas as 12 janelas.

Tabela 5 – Comparação de desempenho por janela temporal (HI Medium - seleção)

Janela	AUPRC (B)	AUPRC (F)	Lift AUPRC	P@100 (B)	P@100 (F)	Lift P@100
4	0,261	0,292	12,0 %	0,99	0,97	−2,0 %
5	0,326	0,392	20,2 %	1,00	1,00	0,0%
7	0,224	0,300	34,2 %	0,96	0,93	−3,1 %
9	0,292	0,360	23,0 %	1,00	1,00	0,0%
11	0,352	0,419	18,9 %	0,99	1,00	1,0%
13	0,258	0,346	34,0 %	1,00	1,00	0,0%
Média (12 janelas)	**0,269**	**0,320**	**19,0 %**	**0,973**	**0,961**	**−1,2 %**

Fonte: Elaborado pelo autor.

A análise temporal no HI Medium mostra um padrão robusto: o modelo completo apresentou ganhos positivos de AUPRC nas 12 janelas testadas, com *lifts* variando entre +0,7% e +34,2%. A janela 3 apresentou ganho marginal (+0,7%), enquanto as demais mostraram contribuições mais expressivas. Destaca-se a variabilidade maior em comparação ao HI Small, sugerindo que a escala aumentada do *dataset* captura dinâmicas temporais mais complexas.

Para as métricas de *Precision@100*, observa-se um padrão heterogêneo similar ao HI Small: em algumas janelas, o modelo *Baseline* mantém desempenho ligeiramente superior, o que sugere que para alertas de altíssimo risco, os atributos comportamentais isolados já fornecem sinais preditivos robustos em escalas maiores. No entanto, o ganho geral em AUPRC (+19,0% na média por janela) demonstra que a vantagem das *features* topológicas emerge quando se expande o horizonte investigativo para alertas de médio risco.

4.2 **Validação Estatística do Estudo de Ablação**

Para determinar se os ganhos observados são estatisticamente significativos e não resultam de variações aleatórias, foram aplicados testes t pareados sobre as diferenças de desempenho entre os dois modelos ao longo das janelas de teste.

4.2.1 Testes Estatísticos no HI Small

A Tabela 6 apresenta os resultados para o *dataset* HI Small.

Tabela 6 – Testes de significância estatística (HI Small, teste t pareado, $\alpha = 0{,}05$)

Métrica	**Δ Médio**	**Desvio Padrão**	**Estatística t**	**p-valor**
Acurácia	0,0789	0,0627	−3,08	0,0273*
Precisão	0,0212	0,0118	−4,40	0,0070**
F1-Score	0,0363	0,0191	−4,67	0,0055**
ROC-AUC	0,0300	0,0148	−4,96	0,0042**
AUPRC	0,0452	0,0324	−3,42	0,0188*
Recall	−0,0227	0,0832	0,67	0,5340
P@100	−0,0217	0,0337	1,57	0,1763
P@200	0,0208	0,0497	−1,03	0,3520
P@300	0,0539	0,0349	−3,79	0,0128*
P@500	0,0637	0,0419	−3,72	0,0137*

* Significativo em $\alpha = 0{,}05$ ** Significativo em $\alpha = 0{,}01$

Fonte: Elaborado pelo autor.

Os testes confirmam que os ganhos observados em acurácia, precisão, F1-Score, ROC-AUC e AUPRC são estatisticamente significativos ao nível de confiança de 95% ($p < 0{,}05$). Em particular, as métricas de precisão, F1-Score e ROC-AUC apresentaram significância ao nível de 99% ($p < 0{,}01$), o que valida a contribuição das *features* topológicas.

A ausência de significância estatística no *Recall* ($p = 0{,}534$) e nas métricas P@100 e P@200 sugere que, embora haja variação numérica, essas diferenças podem ser atribuídas à variabilidade natural das janelas temporais. Entretanto, as métricas P@300 ($p = 0{,}0128$) e P@500 ($p = 0{,}0137$) apresentaram ganhos estatisticamente significativos, reforçando o argumento de que as *features* topológicas contribuem especialmente para a discriminação de entidades em níveis intermediários de risco, onde a separação entre fraudes e operações lícitas torna-se mais difícil.

4.2.2 Testes Estatísticos no HI Medium

A Tabela 7 apresenta os testes de significância para o *dataset* HI Medium, ao longo das 12 janelas de teste.

Tabela 7 – Testes de significância estatística (HI Medium, teste t pareado, $\alpha = 0{,}05$)

Métrica	**Δ Médio**	**Desvio Padrão**	**Estatística t**		**p-valor**
Acurácia	0,0446	0,0495	−3,122		0,0097**
Precisão	0,0222	0,0168	−4,566		0,0008**
F1-Score	0,0366	0,0273	−4,646		0,0007**
ROC-AUC	0,0268	0,0048	−19,537	<	0,0001**
AUPRC	0,0510	0,0306	−5,782		0,0001**
Recall	−0,0175	0,0698	0,870		0,4029
P@100	−0,0117	0,0333	1,215		0,2497
P@200	−0,0258	0,0477	1,877		0,0872
P@300	−0,0261	0,0482	1,878		0,0872
P@500	−0,0013	0,0495	0,093		0,9274

** Significativo em $\alpha = 0{,}01$

Fonte: Elaborado pelo autor.

Os testes no HI Medium mostram uma significância estatística ainda maior para acurácia, precisão, F1-Score, ROC-AUC e AUPRC, todos com $p < 0{,}01$. A significância elevada para ROC-AUC ($p < 0{,}0001$), indica que a discriminação geral entre fraudes e operações legítimas beneficia-se consistentemente das *features* topológicas em toda a janela temporal. De forma similar ao HI Small, não há significância estatística em Recall, P@100, P@200 e P@300, sugerindo que os modelos capturam igualmente bem as fraudes de altíssimo risco, diferenciando-se principalmente em médios níveis de risco.

4.3 **Captura de Entidades Fraudulentas em Nível Operacional**

4.3.1 Análise em Nível de Entidades

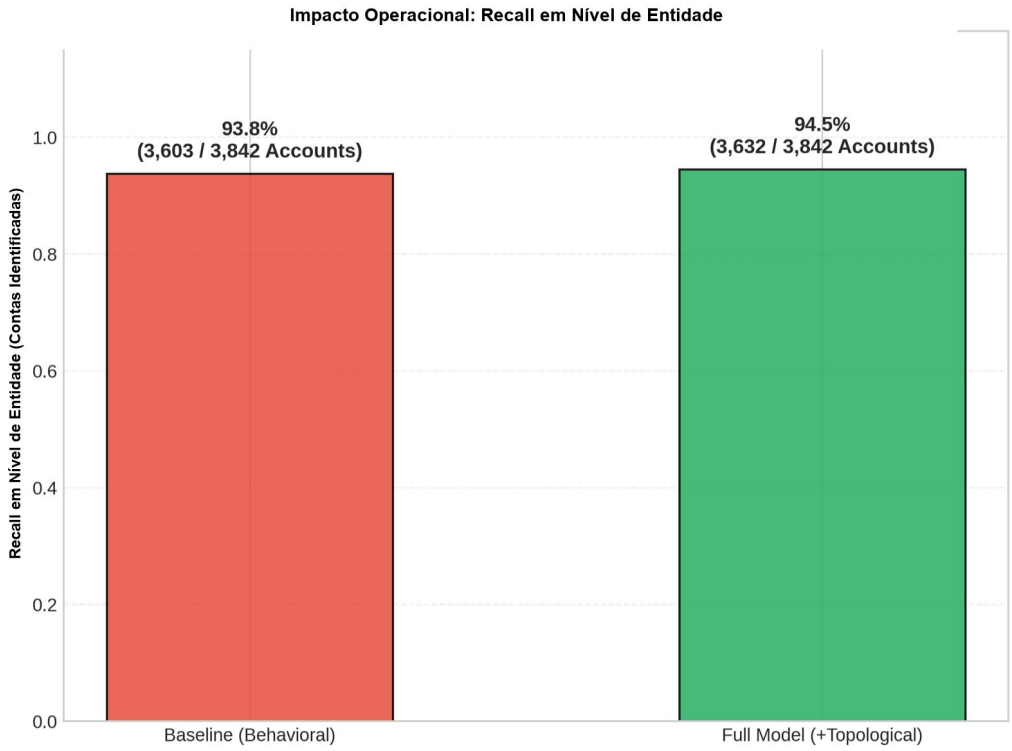
Além das métricas agregadas, avaliou-se a eficácia dos modelos no HI Small e HI Medium em encontrar entidades fraudulentas únicas durante o período de teste. Isso simula a quantidade de criminosos que podem ser identificados pelo modelo, mesmo que os mesmos utilizem mais de uma conta bancária para suas atividades.

No HI Small, do total de 3.842 entidades ilícitas presentes no conjunto de validação:

- **Modelo Baseline:** Detectou 3.603 entidades (93,78% de cobertura).
- **Modelo Full:** Detectou 3.632 entidades (94,53% de cobertura).

Embora a diferença absoluta seja de apenas 29 entidades adicionais (+0,75 pontos percentuais), esse ganho incremental representa uma melhoria relativa de 0,80% na taxa de captura em relação ao modelo base, conforme ilustrado na Figura 7. Em um contexto de *compliance* em larga escala, onde cada entidade fraudulenta não detectada pode resultar em perdas financeiras significativas e penalidades regulatórias, esse incremento possui valor prático mensurável.

Figura 7 – Captura de entidades fraudulentas: Baseline vs Full Model (HI Small)



Fonte: Elaborado pelo autor.

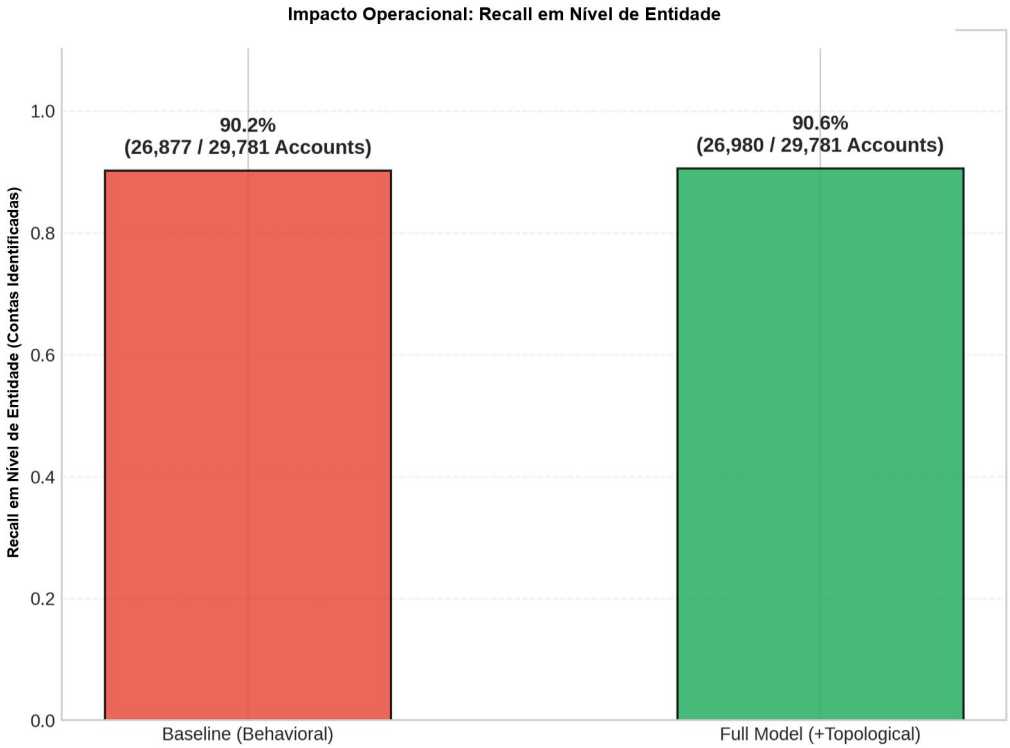
No HI Medium, do total de 29.781 entidades ilícitas presentes no conjunto de validação:

- **Modelo Baseline:** Detectou 26.877 entidades (90,25% de cobertura).
- **Modelo Full:** Detectou 26.980 entidades (90,59% de cobertura).

A diferença absoluta é de 103 entidades adicionais (+0,34 pontos percentuais), o que representa uma melhoria relativa de 0,38% na taxa de captura em relação ao modelo base, conforme detalhado na Figura 8. Embora a captura incremental de 103 entidades fraudulentas no HI Medium seja maior que a de 29 no HI Small, o dataset apresenta uma melhoria percentual menor comparada ao HI Small.

A consistência nos ganhos de AUPRC (+18.88%) entre HI Small e HI Medium, apesar da diferença de escala de 6x, demonstra que o benefício das *features* topológicas

Figura 8 – Captura de entidades fraudulentas: Baseline vs Full Model (HI Medium)



Fonte: Elaborado pelo autor.

não sofre degradação com aumento do volume de dados. Esse resultado tem implicações importantes para a viabilidade de implantação em ambientes de produção com volumes ainda maiores.

4.4 **Importância Global das Features via SHAP**

Para interpretar o comportamento do modelo e identificar quais atributos exercem maior influência nas predições, aplicou-se a técnica SHAP (*SHapley Additive exPlanations*) (LUNDBERG; LEE, 2017) ao modelo completo. Devido à alta complexidade computacional para calcular permutações de 49 features, a análise SHAP de cada janela foi calculada sobre uma amostragem aleatória controlada de 1.000 instâncias de teste.

4.4.1 Análise SHAP no HI Small

A Tabela 8 apresenta as 15 *features* de maior importância global no *dataset* HI Small.

Tabela 8 – Top 15 features por importância SHAP global (HI Small)

Posição	Feature	SHAP Médio	Tipo
1	ach_count_sent	0,9514	Comportamental
2	ach_count_recv	0,7401	Comportamental
3	hits_auth	0,6513	Topológico
4	in_degree	0,3829	Topológico
5	cheque_count_sent	0,3103	Comportamental
6	vol_recv	0,2884	Comportamental
7	average_neighbor_degree	0,2308	Topológico
8	degree	0,2258	Topológico
9	hits_hub	0,2186	Topológico
10	leiden_macro_modularity	0,1767	Topológico
11	successor_avg_volume	0,1760	Topológico
12	pr_count	0,1751	Topológico
13	egonet_node_count	0,1677	Topológico
14	vol_sent	0,1614	Comportamental
15	cheque_count_recv	0,1490	Comportamental

Fonte: Elaborado pelo autor.

A análise revela que as duas *features* mais influentes são comportamentais (`ach_count_sent` e `ach_count_recv`), o que corrobora a intuição de que transações via *Automated Clearing House* (ACH) são frequentemente associadas a esquemas de fraude no *dataset* AMLworld. No entanto, as posições subsequentes são dominadas por atributos topológicos, incluindo a pontuação de autoridade do algoritmo HITS (`hits_auth`), o grau de entrada (`in_degree`) e métricas de vizinhança.

Entre os atributos topológicos, destaca-se a importância de:

- **Centralidade (HITS e Grau):** Entidades fraudulentas tendem a ocupar posições centrais na rede, seja como concentradoras de fluxo financeiro (*hits_auth*) ou como nós de dispersão (*hits_hub*).
- **Métricas de Comunidade:** A modularidade da macro-comunidade (`leiden_macro_modulari`) captura o nível de isolamento topológico de um vértice, indicando se ele faz parte de um anel financeiro fechado e compartimentado.
- **Agregação de Vizinhança:** O grau médio dos vizinhos (`average_neighbor_degree`) e o volume médio enviado aos sucessores (`successor_avg_volume`) fornecem sinais sobre o comportamento pós-transferência, revelando se o dinheiro é imediatamente dispersado ou concentrado após a transação inicial.

A distribuição equilibrada entre *features* comportamentais e topológicas no gráfico SHAP sugere que ambos os tipos de informação são complementares e necessários para

uma detecção eficaz de lavagem de dinheiro.

O gráfico de dispersão SHAP (*beeswarm plot*), ilustrado na Figura 9, sintetiza tanto a magnitude da importância de cada variável quanto o sentido e a natureza do seu impacto nas decisões do modelo. Cada linha representa uma *feature*, disposta verticalmente em ordem decrescente de importância global, enquanto o eixo horizontal mede o valor SHAP (*SHAP value*), que indica o quanto a presença daquela variável desvia a predição da saída média do modelo (valores à direita aumentam a probabilidade de fraude, enquanto valores à esquerda a reduzem). Cada ponto na linha corresponde a uma transação individual da amostra, e a sua cor indica o valor real assumido pela variável naquela instância: tons de vermelho/rosa representam valores altos da *feature*, ao passo que tons de azul representam valores baixos. A espessura ou densidade vertical de pontos em torno de uma determinada posição reflete o volume de instâncias que compartilham impactos similares. Dessa forma, além de identificar quais variáveis governam as decisões, o gráfico permite diagnosticar relações de causa e efeito (por exemplo, se valores elevados de uma métrica favorecem ou inibem a classificação de anomalia).

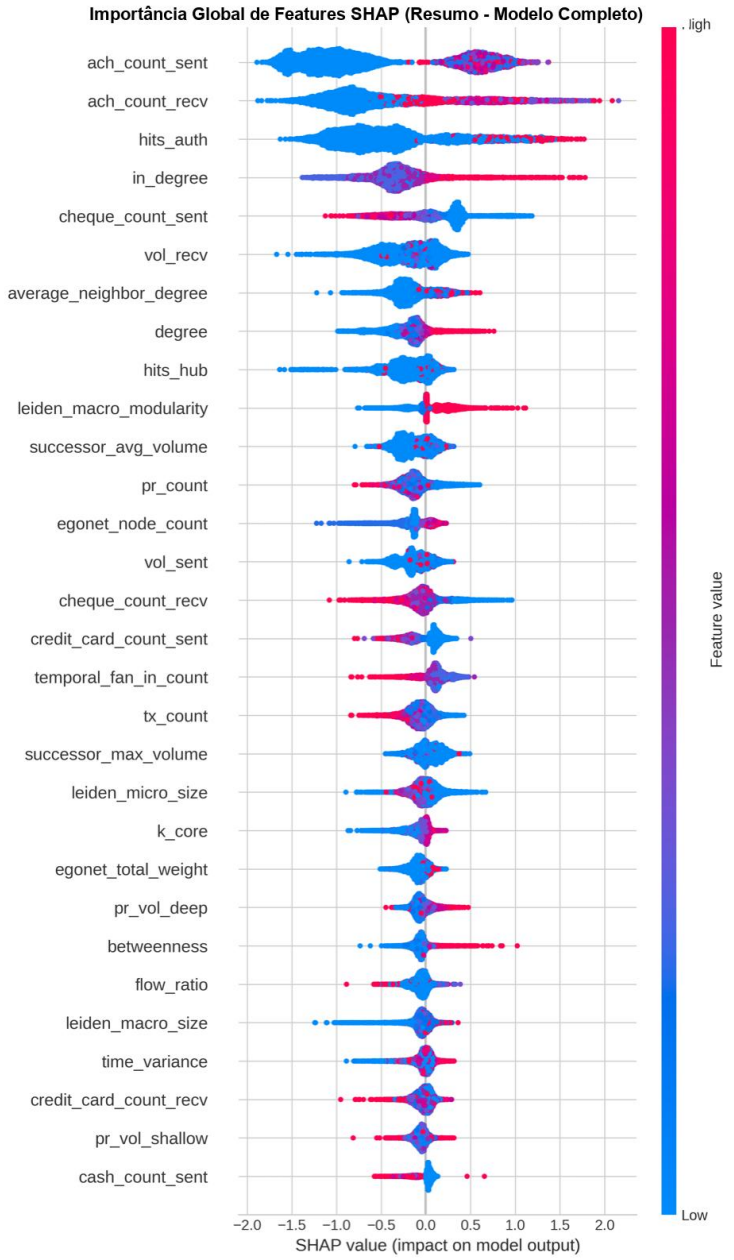
A inspeção da dispersão dos pontos na Figura 9 permite entender como os valores de cada variável influenciam as decisões do modelo no *dataset* HI Small:

- **Transferências eletrônicas ACH** (`ach_count_sent` e `ach_count_recv`): Os pontos vermelhos (que indicam valores altos) concentram-se fortemente do lado direito (valores SHAP positivos, chegando a passar de +1,0 no envio e +2,0 no recebimento). Já os pontos azuis (valores baixos ou zerados) ficam do lado esquerdo (valores SHAP negativos). Isso mostra que realizar muitas transferências eletrônicas via ACH — tanto enviando quanto recebendo — é o sinal mais forte de suspeita de fraude para o modelo. Esse comportamento reflete a prática comum de criminosos, que utilizam transferências eletrônicas rápidas para movimentar, fracionar (*smurfing*) e esvaziar contas antes que sejam bloqueadas.

- **Contas que concentram recursos** (`hits_auth` e `in_degree`): As duas variáveis de grafo mais bem posicionadas (3ª e 4ª posições) mostram uma longa faixa de pontos vermelhos do lado positivo à direita (SHAP de até +1,8). A métrica `hits_auth` identifica se uma conta recebe dinheiro de várias contas intermediárias que distribuem recursos. No contexto de combate à fraude, essa é a característica clássica de contas de coleta ou "contas-mula", que juntam o dinheiro fracionado vindo de diversos remetentes para repassá-lo adiante. Da mesma forma, um grau de entrada alto (`in_degree`) indica que a conta recebeu recursos de muitos parceiros distintos, aumentando bastante a probabilidade de alerta.

- **Uso de cheques como indicativo legítimo** (`cheque_count_sent` e `cheque_count_recv`): Ao contrário do ACH, a variável `cheque_count_sent` (5ª posição) apresenta um

Figura 9 – Distribuição de valores SHAP para as principais features do modelo (HI Small)



Fonte: Elaborado pelo autor.

comportamento inverso: pontos vermelhos (muitos cheques emitidos) ficam do lado esquerdo (SHAP negativo, entre −0,8 e −0,2), enquanto pontos azuis (poucos ou nenhum cheque) concentram-se do lado direito (SHAP positivo). O mesmo padrão reverso ocorre em `cheque_count_recv` (15ª posição). Isso acontece porque o cheque é um meio de pagamento mais lento, formal e rastreável, típico de comércios e empresas tradicionais. O modelo aprendeu que a movimentação regular de cheques funciona como um indicativo de legitimidade (um fator de proteção), ao passo que a ausência total de cheques em contas que movimentam muito dinheiro eletrônico eleva o nível de suspeita.

- **Volume de dinheiro recebido** (`vol_recv`): Em `vol_recv` (6ª posição), os pontos azuis (volumes muito baixos) ficam bem à esquerda no gráfico (SHAP em torno de −1,5). Isso significa que contas que movimentam valores quase nulos são rapidamente descartadas como suspeitas pelo modelo.

- **Conexões e grupos fechados** (`average_neighbor_degree`, `degree` e `leiden_macro_modular`
  As variáveis de vizinhança mostram que estar conectado a contas que também transacionam intensamente eleva a suspeita sobre o titular. Além disso, na modularidade (`leiden_macro_modularity`, 10ª posição), valores altos (pontos vermelhos) ficam do lado direito (SHAP positivo até +1,0). Isso indica que contas que operam dentro de grupos muito fechados e isolados da rede têm maior chance de serem fraudulentas, o que reproduz o padrão de quadrilhas que circulam recursos apenas entre cúmplices antes de tentar sacar ou transferir para fora da rede.

4.4.2 Análise SHAP no HI Medium

A Tabela 9 apresenta as 15 *features* de maior importância global no *dataset* HI Medium, permitindo avaliar se a hierarquia de importância é preservada em escala maior.

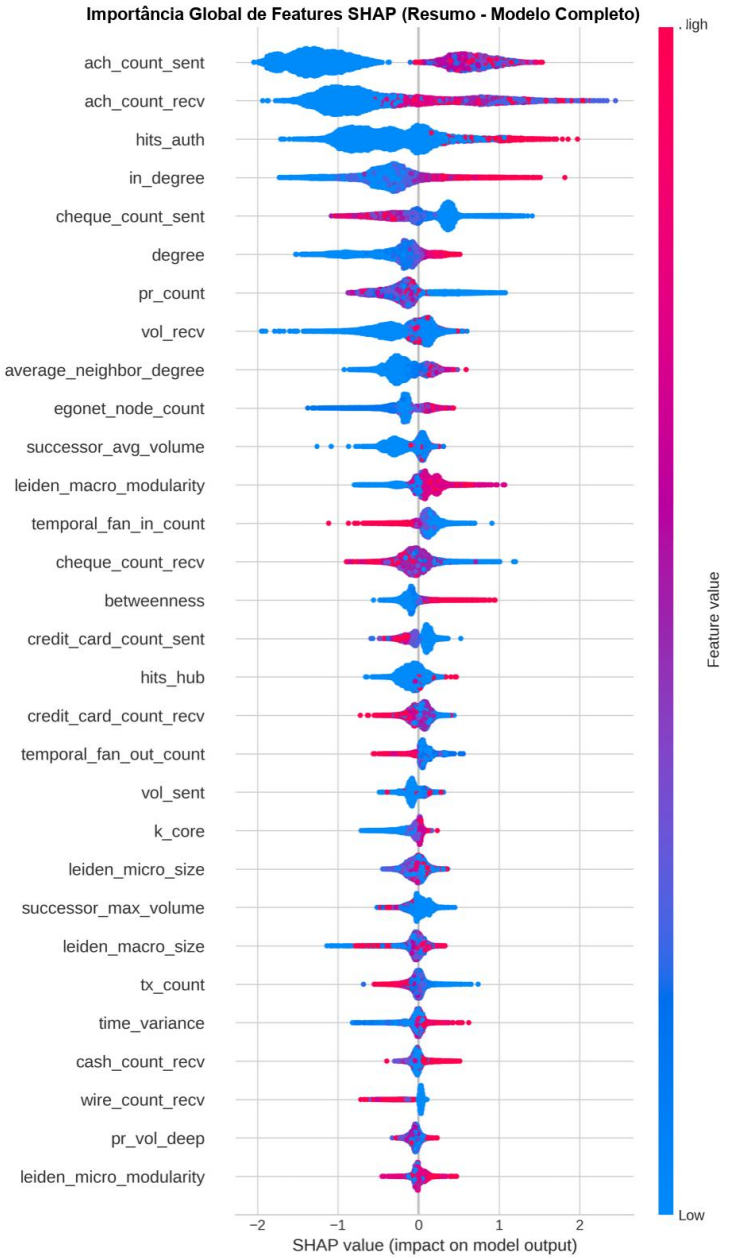
Ao comparar as Tabelas 8 e 9, nota-se que as variáveis mais determinantes permanecem as mesmas: as cinco primeiras posições são idênticas em ambos os conjuntos (`ach_count_sent`, `ach_count_recv`, `hits_auth`, `in_degree` e `cheque_count_sent`). Além disso, a importância média dessas variáveis de topo aumenta na rede maior: o SHAP de `ach_count_sent` sobe de 0,9514 no Small para 1,0822 no Medium, e o de `ach_count_recv` vai de 0,7401 para 0,8111.

A Figura 10 apresenta a distribuição global de valores SHAP para o modelo treinado no HI Medium, permitindo avaliar o comportamento das variáveis em uma rede seis vezes maior.

A partir do gráfico da Figura 10, destacam-se os seguintes resultados:

- **Sinais do topo ainda mais evidentes:** As variáveis `ach_count_sent`, `ach_count_recv`,

Figura 10 – Distribuição de valores SHAP para as principais features do modelo (HI Medium)



Fonte: Elaborado pelo autor.

Tabela 9 – Top 15 features por importância SHAP global (HI Medium)

Posição	Feature	SHAP Médio	Tipo
1	ach_count_sent	1,0822	Comportamental
2	ach_count_recv	0,8111	Comportamental
3	hits_auth	0,5033	Topológico
4	in_degree	0,4207	Topológico
5	cheque_count_sent	0,3177	Comportamental
6	degree	0,3135	Topológico
7	pr_count	0,2677	Topológico
8	vol_recv	0,2567	Comportamental
9	average_neighbor_degree	0,2226	Topológico
10	egonet_node_count	0,2202	Topológico
11	successor_avg_volume	0,1861	Topológico
12	leiden_macro_modularity	0,1526	Topológico
13	temporal_fan_in_count	0,1503	Topológico
14	cheque_count_recv	0,1371	Comportamental
15	betweenness	0,1232	Topológico

Fonte: Elaborado pelo autor.

hits_auth e in_degree mantêm a mesma direção observada no HI Small, mas seus pontos positivos espalham-se ainda mais para a direita. No caso de ach_count_recv, os valores chegam a ultrapassar +2,5, e em hits_auth superam +1,7. Isso mostra que, em uma rede muito maior e com mais clientes normais, as contas que centralizam recursos e recebem grandes volumes eletrônicos tornam-se ainda mais fáceis de distinguir do comportamento legítimo.

- **Maior peso da conectividade geral** (degree e pr_count): O total de conexões da conta (degree) subiu da 8ª posição no HI Small para a 6ª no HI Medium (SHAP de 0,3135), e o PageRank (pr_count) subiu da 12ª para a 7ª posição (0,2677). Em redes maiores, a maioria das pessoas comuns interage com poucos parceiros e de forma dispersa. Já as redes de fraude precisam criar várias contas e fluxos interligados para movimentar o dinheiro, fazendo com que o número total de conexões e a relevância no fluxo financeiro ganhem ainda mais peso na classificação.

- **Concentração de contatos próximos** (egonet_node_count): A quantidade de vizinhos diretos ao redor da conta subiu da 13ª para a 10ª posição (0,2202). No gráfico, valores altos dessa métrica (pontos magenta) puxam a predição para o lado positivo, indicando que contas inseridas em grupos densos de contatos próximos têm maior chance de participar de esquemas coordenados.

- **Detecção de transferências em rajada** (temporal_fan_in_count): Uma no-

vidade no HI Medium é o ingresso de `temporal_fan_in_count` no Top 15 (13ª posição, SHAP de 0,1503). Essa métrica mede se a conta recebeu muitas transações em uma janela curta de tempo. Em redes amplas, quadrilhas costumam realizar vários depósitos rápidos e concentrados para diminuir o tempo em que o dinheiro fica exposto antes do saque. O modelo aprendeu a identificar esse comportamento em rajada, associando valores altos a maior probabilidade de fraude.

- **Contas intermediárias como pontes** (`betweenness`): A centralidade de intermediação (`betweenness`) subiu para a 15ª posição (SHAP de 0,1232, contra a 21ª colocação no Small), com pontos vermelhos atingindo SHAP de até +1,3. Em redes maiores, contas que funcionam como pontes ligando grupos ou bancos diferentes tornam-se essenciais para detectar esquemas que usam contas de passagem para esconder a origem dos recursos.

- **Confirmação do papel protetivo dos cheques:** O uso de cheques (`cheque_count_sent` e `cheque_count_recv`) preserva o mesmo comportamento inverso: quem movimenta cheques continua recebendo pontuação menor de risco, enquanto a ausência de cheques eleva a suspeita. Isso comprova que a preferência dos fraudadores por canais puramente eletrônicos é uma característica estável, independentemente do tamanho da base analisada.

4.5 Métricas Topológicas dos Algoritmos

Foram também geradas métricas de avaliação para cada algoritmo de forma isolada, permitindo uma análise de quais são os mais robustos para discriminar entidades ilícitas em diferentes cenários. Para evitar uma descrição exaustiva das mais de vinte métricas avaliadas, os algoritmos foram agrupados de acordo com seus perfis de desempenho e comportamentos estruturais no grafo de transações. A Tabela 10 consolida os principais indicadores dos agrupamentos mais relevantes, servindo como âncora numérica para a interpretação crítica subsequente.

Os resultados experimentais revelam uma dicotomia clara entre capacidade de ranqueamento global e precisão em horizontes estritos de decisão. O grupo dos *Rankers Globais*, liderado por `ACH_COUNT_SENT` (ROC-AUC de 0,7422), `HITS_HUB` (0,7315 no HI Small e 0,7542 no HI Medium) e `OUT_DEGREE` (0,7225 no HI Small e 0,7609 no HI Medium), demonstrou a maior robustez para discriminar entidades lícitas de ilícitas ao longo de toda a curva de operação. Sob a ótica topológica, esse comportamento indica que os esquemas de lavagem de dinheiro são fortemente caracterizados pela dispersão ativa e pela volumetria de saída de transações realizadas por nós intermediários.

Em contrapartida, métricas locais centradas na contagem bruta, como `TX_COUNT`

Tabela 10 – Resumo comparativo dos agrupamentos métricos estruturais

Perfil coesivo	**Métrica representativa**	**ROC-AUC**	**Avg. Precision**	**P@10**	**Descrição**
Rankers globais	`ACH_COUNT_SENT`, `HITS_HUB`, `OUT_DEGREE`	0,7422–0,7609	0,0636–0,0888	100,00%	Sinal forte de dispersão ativa de saída
Filtros de triagem	`TX_COUNT`, `PR_COUNT`	0,6014–0,6782	0,0748–0,0938	100,00%	Excelente primeira barreira operacional
Assimetria de papel	`HITS_AUTH`	0,6209	0,0174	0,00%–10,00%	Contas de destino se ocultam no fluxo normal
Baixo sinal	`BITCOIN_COUNT_RECV`, `TIME_VARIANCE`	0,5018–0,6181	0,0146–0,0171	0,00%–6,25%	Candidatas à poda por baixo poder discriminativo
Leiden	Comunidades macroestruturais	Q = 0,6588–0,7898	–	–	Boa partição matemática, mas com diluição fraudulenta

Fonte: Elaborado pelo autor.

(ROC-AUC de 0,6412) e `PR_COUNT` (0,6014), embora exibam menor poder de separação global, alcançam Precision@10 de 100,00%. Do ponto de vista prático de engenharia de risco, esses algoritmos funcionam como filtros de topo de funil, ideais para triagem primária. Eles não resolvem o problema de classificação da base como um todo, mas são extremamente eficazes para concentrar a investigação nas anomalias mais evidentes da rede.

Um dos achados mais ricos da análise crítica reside na assimetria estrutural exposta pelo algoritmo HITS. Enquanto o perfil de *hub* (`HITS_HUB`) obteve desempenho expressivo, o perfil de autoridade (`HITS_AUTH`) colapsou para uma Average Precision média de 0,0174 e mediana de Precision@10 igual a 0,00%. Esse contraste sugere que as redes criminosas estruturam-se para tornar visíveis as contas de distribuição e intermediação, ao mesmo tempo em que camuflam as contas de destino final. Em termos legais e operacionais, o sinal da fraude aparece na periferia operacional do fluxo, não no ponto terminal onde o capital é finalmente absorvido.

Métricas de contexto financeiro muito específicas, como `BITCOIN_COUNT_RECV` (ROC-AUC de 0,5018) e `TIME_VARIANCE` (0,5883 no HI Small e 0,6181 no HI Medium), apresentaram desempenho similar ao aleatório. Essa proximidade com o acaso, combinada a Average Precision muito baixa, indica baixo valor informacional para a tarefa de ranking. Em um pipeline de produção, esses atributos tendem a aumentar custo computacional sem entregar sinal preditivo proporcional.

4.5.1 O Paradoxo Estrutural do Algoritmo de Leiden

A aplicação do algoritmo de Leiden para detecção de comunidades revelou um paradoxo metodológico relevante para a prevenção à lavagem de dinheiro. Por um lado,

as métricas de qualidade são excelentes: o escore médio de modularidade (Q) permaneceu alto em todas as janelas observadas, oscilando entre 0,6588 e 0,7898, o que atesta partições matematicamente consistentes e estruturalmente densas.

Por outro lado, Leiden falha como filtro autônomo devido ao efeito de diluição em macrocomunidades. No HI Small, 156.844 de 165.832 nós atribuídos (94,60%) concentraram-se em comunidades com mais de 500 integrantes, enquanto no HI Medium esse número chegou a 635.056 de 665.127 (95,48%). Nesses grandes agregados, a taxa de fraude interna converge para a linha de base da rede, chegando a 0,9749% no HI Small e 0,8673% no HI Medium. Além disso, as comunidades de maior risco capturam apenas frações marginais da fraude total, o que mostra que uma boa partição matemática não implica utilidade operacional direta.

Conclui-se, portanto, que o Leiden é valioso como descrição da macroestrutura da rede, mas inviável como filtro isolado de detecção. Seu papel é complementar, servindo para contextualizar a arquitetura relacional do grafo, e não para substituir as métricas locais de centralidade e dispersão que efetivamente carregam o sinal antifraude.

4.6 **Discussão dos Resultados**

Os resultados experimentais confirmam que a incorporação de atributos topológicos extraídos de grafos temporais fornece ganhos estatisticamente significativos na detecção de esquemas de lavagem de dinheiro quando comparada a modelos baseados exclusivamente em *features* comportamentais.

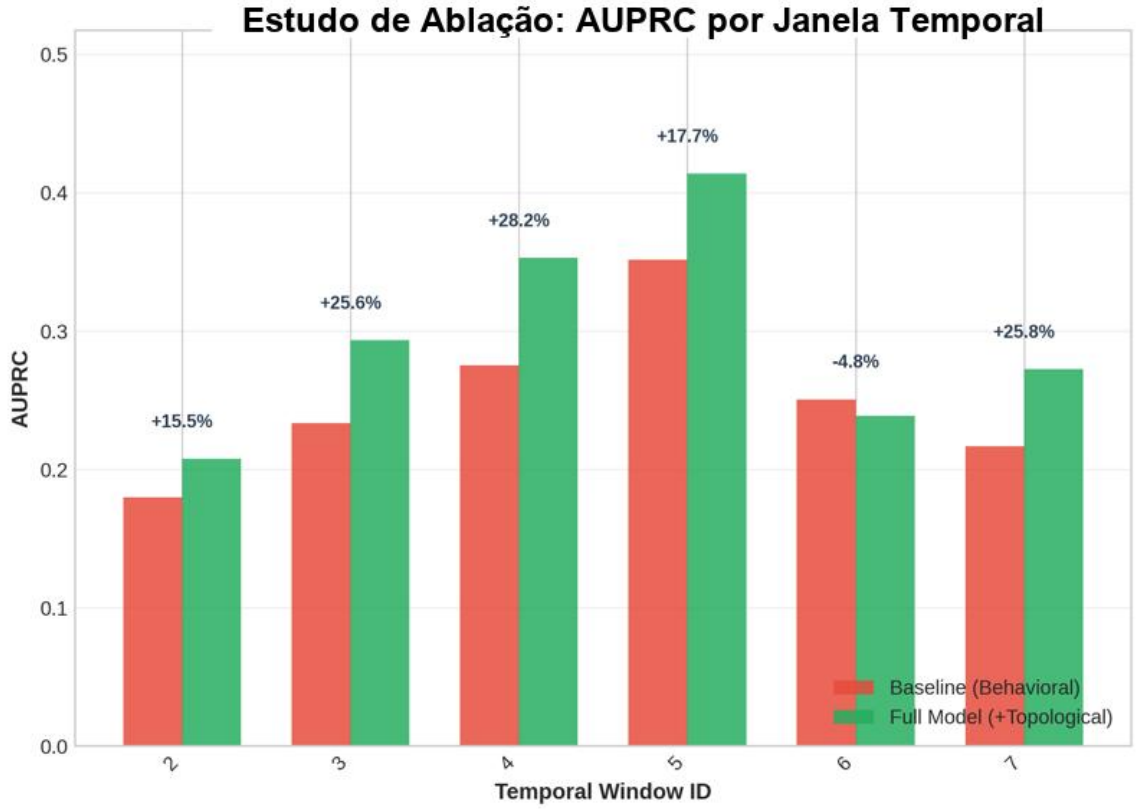
O ganho médio de +18% em AUPRC, validado estatisticamente com $p = 0{,}0188$, demonstra que as propriedades estruturais da rede financeira carregam informação preditiva complementar que não é capturada por análises isoladas de comportamento transacional. Esse resultado alinha-se com a literatura recente, que destaca a importância de abordagens baseadas em grafos para identificar tipologias avançadas de fraude, como *smurfing*, ciclos de transferência e estruturas de dispersão-concentração (CHENG; ZOU; XIANG, 2025; BAIGABYL; NUGUMANOVA; SODNOMOVA, 2025).

A análise de importância via SHAP revelou que, embora as *features* comportamentais tradicionais (especialmente as relacionadas a ACH e cheques) permaneçam altamente relevantes, as métricas topológicas ocupam posições de destaque no ranking de influência. Em particular, o algoritmo HITS e as métricas de grau demonstraram alta capacidade discriminativa, sugerindo que entidades fraudulentas tendem a ocupar posições estruturalmente distintas na rede: seja como pontos de concentração de fluxo (*authority*) ou como nós dispersores (*hub*).

A validação temporal do estudo de ablação, realizada através de *forward-chaining* em 6 janelas consecutivas, confere robustez aos resultados. A evolução comparativa do

AUPRC, o ganho incremental absoluto (ΔAUPRC) e a estabilidade da métrica Precisão@100 ao longo das janelas são ilustrados nas Figuras 11, 12 e 13 para o *dataset* HI Small, e nas Figuras 14, 15 e 16 para o HI Medium. A consistência dos ganhos ao longo de 5 das 6 janelas indica que os padrões topológicos aprendidos pelo modelo generalizam bem para períodos futuros, um requisito importante para a implantação em ambientes de produção.

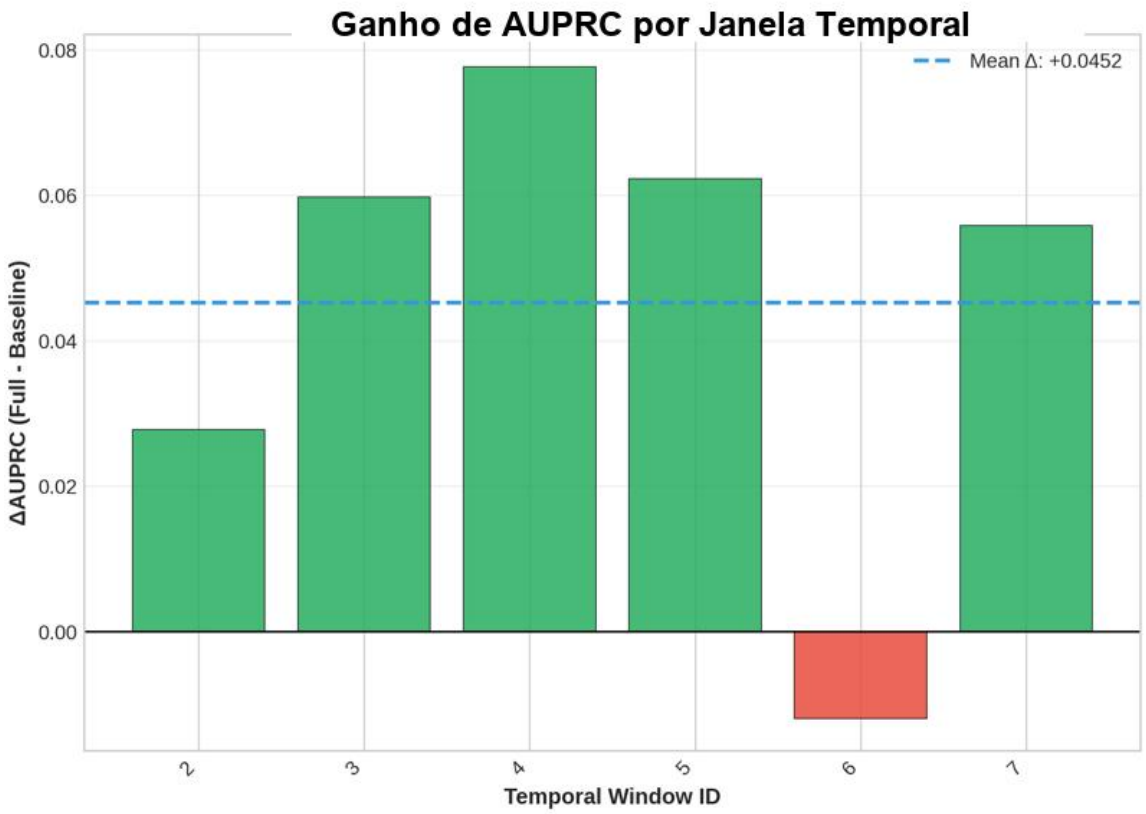
Figura 11 – Comparação de AUPRC e Lift percentual por janela temporal (HI Small)



Fonte: Elaborado pelo autor.

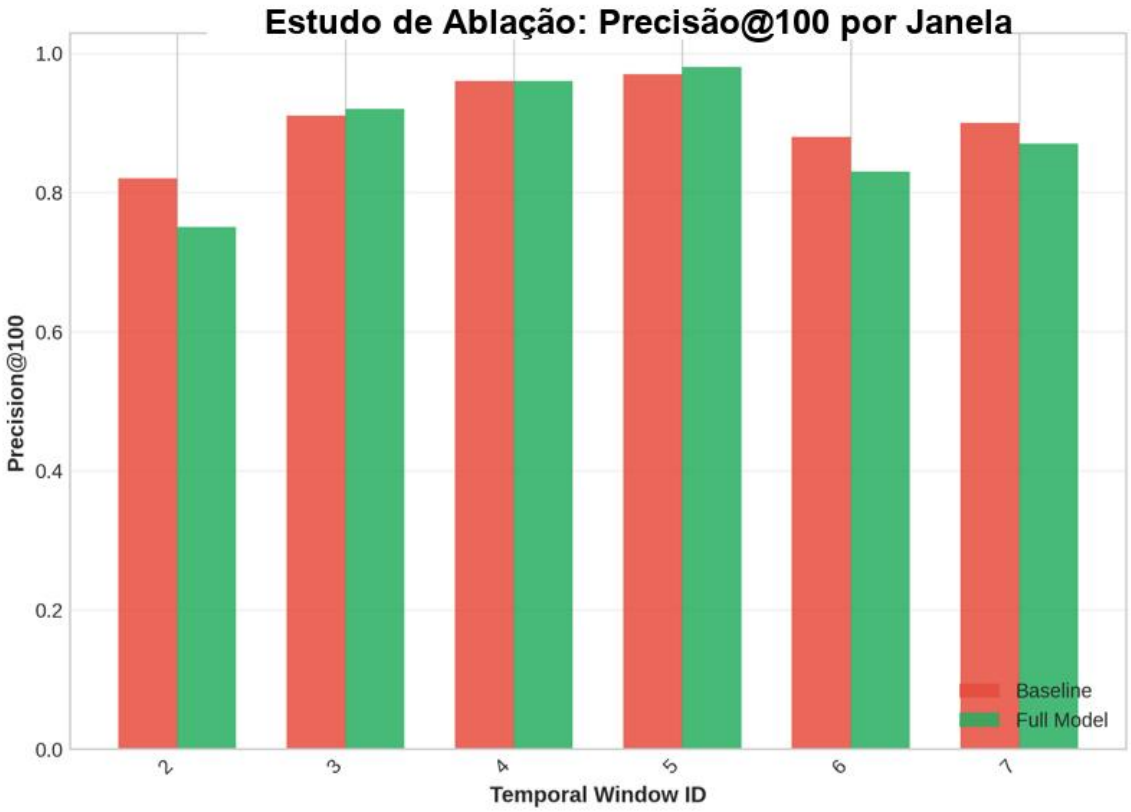
Por outro lado, a redução observada no *Recall* geral (HI Small: -3,08%, HI Medium: -2,00%) e as oscilações nas métricas P@100 e P@200 evidenciam um *trade-off* inerente: ao refinar a fronteira de decisão para minimizar falsos positivos, o modelo torna-se mais conservador em algumas situações, potencialmente deixando de capturar fraudes de baixa sinalização topológica. Esse comportamento é esperado e aceitável no contexto operacional de *compliance*, onde a priorização de alertas de alta confiança reduz a sobrecarga investigativa, mesmo que isso implique em uma pequena perda marginal de cobertura total.

Figura 12 – Ganho absoluto de AUPRC (ΔAUPRC) por janela temporal (HI Small)



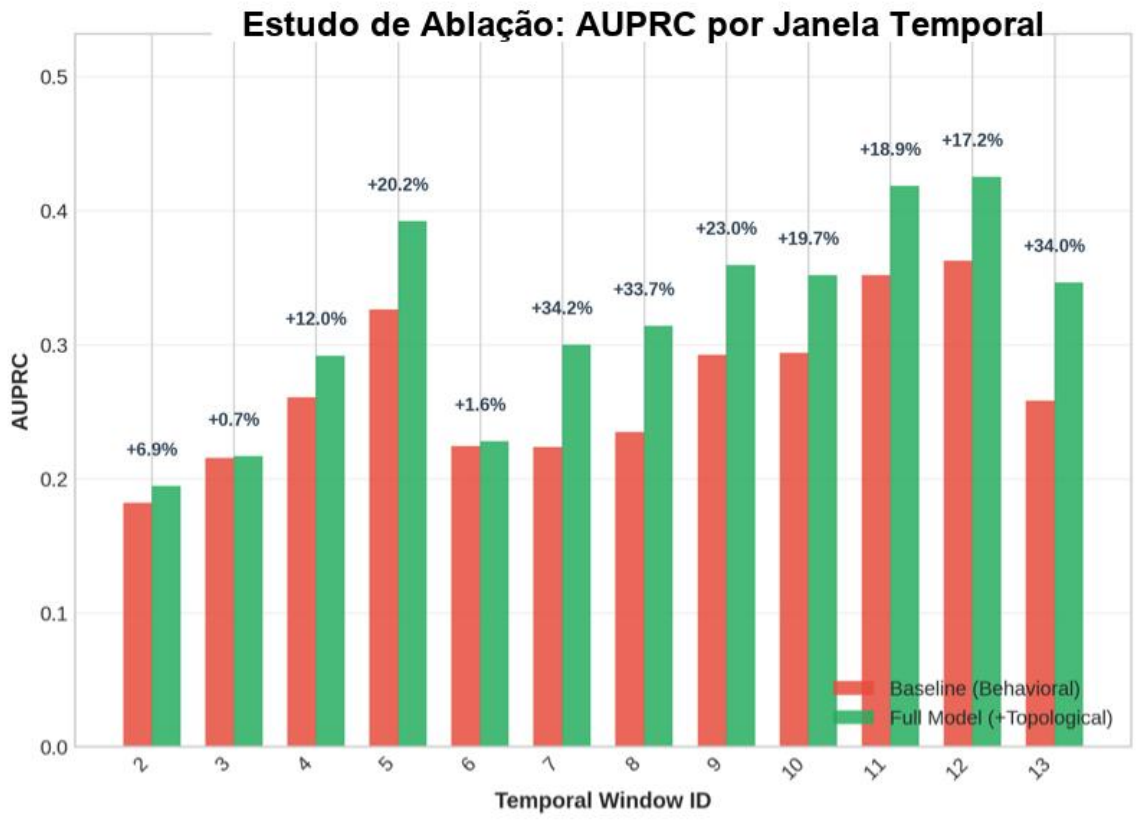
Fonte: Elaborado pelo autor.

Figura 13 – Precisão@100 por janela temporal no estudo de ablação (HI Small)



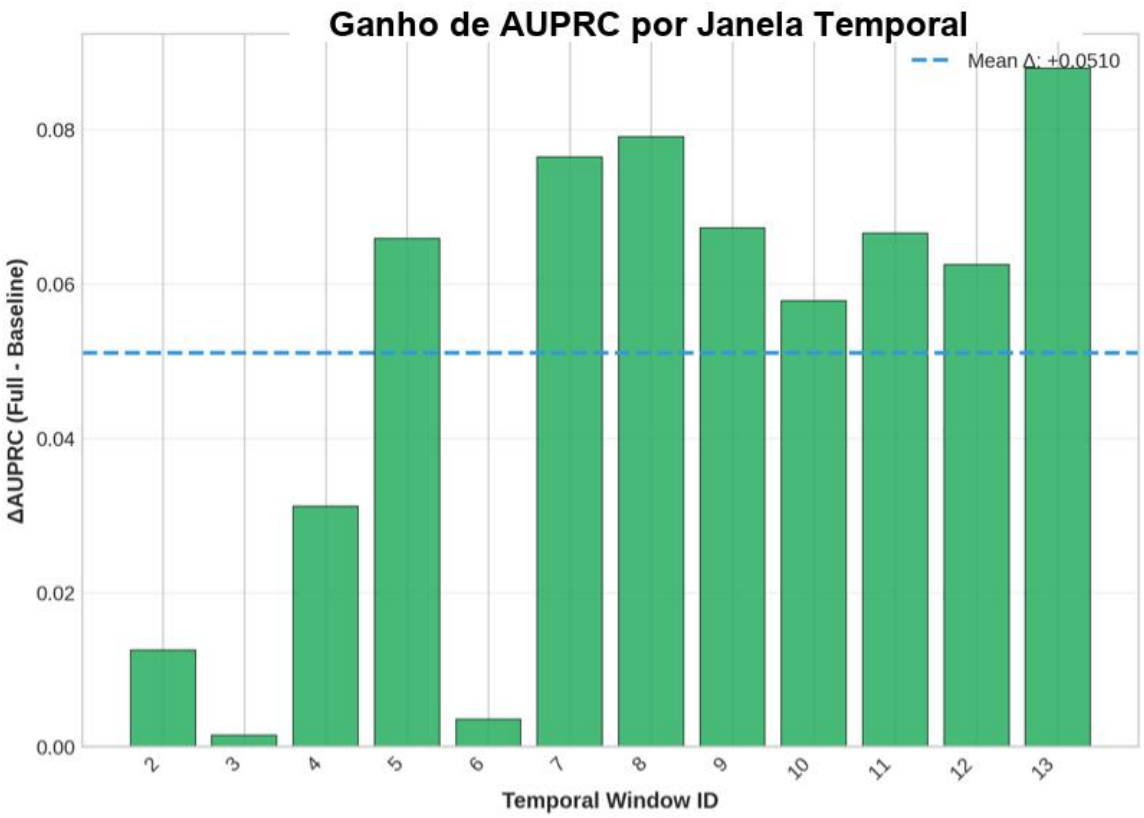
Fonte: Elaborado pelo autor.

Figura 14 – Comparação de AUPRC e Lift percentual por janela temporal (HI Medium)



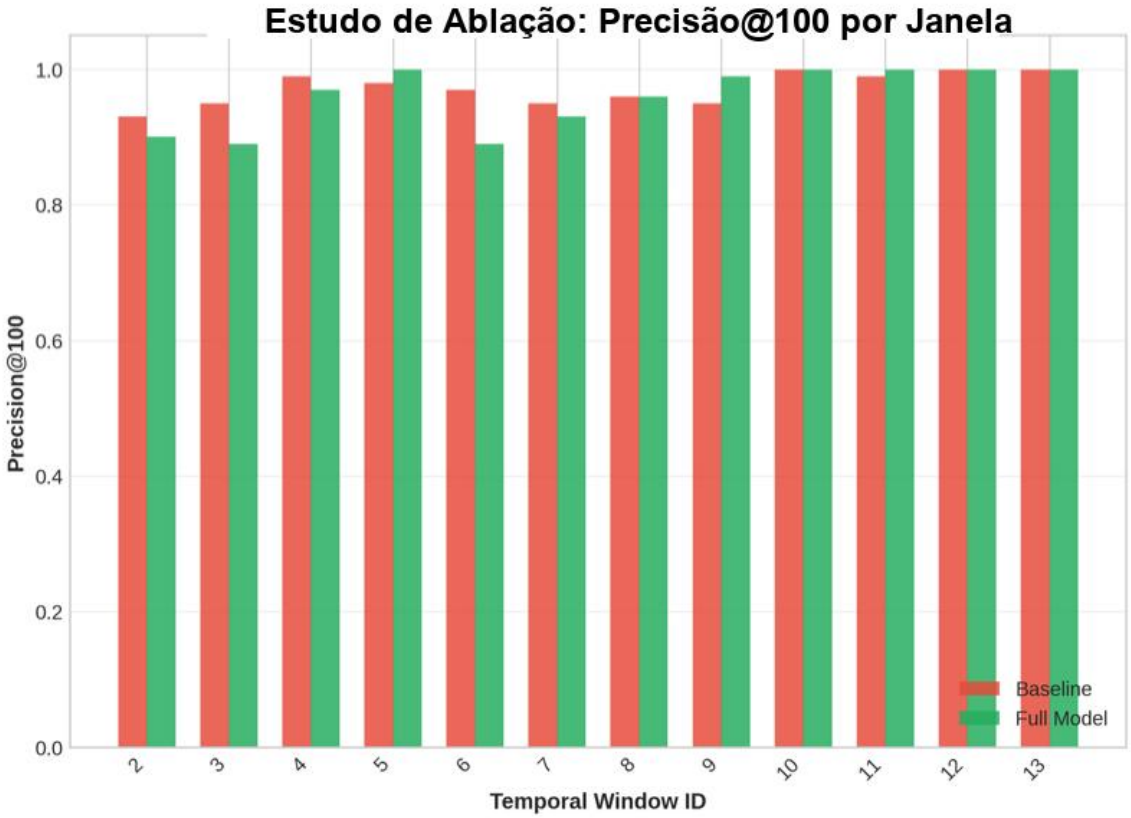
Fonte: Elaborado pelo autor.

Figura 15 – Ganho absoluto de AUPRC (ΔAUPRC) por janela temporal (HI Medium)



Fonte: Elaborado pelo autor.

Figura 16 – Precisão@100 por janela temporal no estudo de ablação (HI Medium)



Fonte: Elaborado pelo autor.

5 CONCLUSÃO

> "Aprenda a ver. Perceba que tudo se conecta a tudo o mais."
>
> *Leonardo da Vinci*

Este trabalho investigou a contribuição de atributos topológicos extraídos de grafos temporais para a detecção de esquemas de lavagem de dinheiro utilizando algoritmos de *Gradient Boosting*. Através de um estudo de ablação controlado e estatisticamente validado, demonstrou-se que a incorporação de *features* estruturais de rede resulta em ganhos significativos de desempenho em relação a modelos baseados exclusivamente em atributos comportamentais.

5.1 Principais Contribuições

Os resultados obtidos confirmam as hipóteses centrais do trabalho e fornecem evidências quantitativas para as seguintes contribuições:

1. **Validação do ganho topológico:** O modelo completo (comportamental + topológico) alcançou AUPRC média de 0,2965, representando um ganho estatisticamente significativo de +18,00% ($p = 0{,}0188$) em relação ao modelo de base (AUPRC = 0,2513). Ganhos similares foram observados em precisão (+46,67%, $p = 0{,}0070$), F1-Score (+41,86%, $p = 0{,}0055$) e ROC-AUC (+3,00%, $p = 0{,}0042$).

2. **Identificação de *features* topológicas críticas:** A análise SHAP revelou que métricas de centralidade (HITS, grau, *PageRank*), detecção de comunidades (Leiden) e agregação de vizinhança ocupam posições de destaque no ranking de importância preditiva, demonstrando que entidades fraudulentas exibem assinaturas estruturais distintas na rede financeira.

3. **Robustez temporal:** A validação via *forward-chaining* em 6 janelas temporais demonstrou consistência dos ganhos ao longo do tempo, indicando que os padrões topológicos aprendidos generalizam para períodos futuros.

5.2 Implicações Práticas

Do ponto de vista operacional, os resultados possuem implicações diretas para equipes de *compliance* de instituições financeiras:

- **Redução de falsos positivos:** Os ganhos em precisão de +46,67% no HI Small e +32,28% no HI Medium implicam em uma redução substancial de alertas falsos, diminuindo a sobrecarga investigativa e permitindo que analistas foquem em casos de alto risco real.
- **Captura incremental de fraudes:** O modelo completo identificou 29 entidades fraudulentas adicionais (0,80% de melhoria relativa), demonstrando que as *features* topológicas capturam padrões estruturais que escapam à análise comportamental isolada.

5.3 Limitações e Trabalhos Futuros

Embora os resultados sejam promissores, o estudo apresenta limitações que devem ser consideradas:

1. **Uso de dados sintéticos:** A validação foi realizada exclusivamente sobre o *dataset* AMLworld, que, apesar de sua fidelidade estrutural, não captura toda a complexidade e diversidade de padrões observados em transações bancárias reais. A aplicação do sistema a dados reais de instituições financeiras é um próximo passo essencial.
2. **Escala computacional:** O processamento de grafos com milhões de nós exige recursos significativos.
3. **Evolução temporal dos padrões:** Organizações criminosas adaptam dinamicamente suas táticas para contornar os mecanismos de fiscalização. Trabalhos futuros devem investigar estratégias de retreinamento contínuo e detecção de desvio de conceito (*concept drift*), isto é, a alteração das propriedades estatísticas e dos padrões de fraude ao longo do tempo, que tende a degradar a acurácia de modelos estáticos, para assegurar a eficácia do sistema em cenários de evolução adversarial.
4. **Explicabilidade para auditoria regulatória:** Embora a técnica SHAP forneça interpretabilidade a nível de *feature*, a justificação de alertas individuais para fins de conformidade e auditoria regulatória exige métodos de explicação a nível de instância. Instituições financeiras estão sujeitas a marcos legais e exigências regulatórias (como as diretrizes do GAFI/FATF, normas do Banco Central e leis de proteção de dados e governança de inteligência artificial), que demandam auditabilidade e rastreabilidade para o bloqueio de operações, descredenciamento de clientes ou envio de comunicações de atividades suspeitas às autoridades competentes (como o COAF). Modelos tratados puramente como "caixas-pretas"tornam-se inviáveis perante tais imposições legais, pois a instituição deve ser capaz de demonstrar os fatores objetivos e contextuais que motivaram cada suspeita. Nesse sentido, trabalhos futuros

devem investigar a integração de técnicas como LIME (*Local Interpretable Model-agnostic Explanations*) e a extração de caminhos e subgrafos de ativação em redes financeiras, fortalecendo a explicabilidade e a auditabilidade jurídica das decisões do modelo (RIBEIRO; SINGH; GUESTRIN, 2016).

5.4 **Considerações Finais**

Este trabalho demonstrou que a modelagem de redes financeiras como grafos temporais e a extração de atributos topológicos fornecem ganhos mensuráveis e estatisticamente validados para a detecção de lavagem de dinheiro. A integração de Ciência de Dados de Grafos com algoritmos de *Gradient Boosting* representa uma abordagem promissora para sistemas de *Anti-Money Laundering*, capaz de capturar tanto o comportamento individual das entidades quanto as propriedades estruturais das redes de transações.

Os resultados reforçam a importância de abordagens multimodais que combinam sinais comportamentais e topológicos, especialmente em cenários onde fraudadores utilizam estratégias sofisticadas de ofuscação, como *smurfing*, ciclos de transferência e estruturas de dispersão-concentração (CHENG; ZOU; XIANG, 2025; TIWARI; GEPP; KUMAR, 2020; Chainalysis, 2025). À medida que os esquemas de lavagem de dinheiro tornam-se cada vez mais complexos e distribuídos, a incorporação de técnicas baseadas em grafos deixa de ser opcional e torna-se um requisito fundamental para a eficácia dos sistemas de detecção de fraudes financeiras.

REFERÊNCIAS BIBLIOGRÁFICAS

AKOGLU, L.; MCGLOHON, M.; FALOUTSOS, C. Oddball: Spotting anomalies in weighted graphs. In: *Advances in Knowledge Discovery and Data Mining (PAKDD)*. Springer, 2010. p. 410–421. Disponível em: https://doi.org/10.1007/978-3-642-13672-6_40.

ALARAB, I.; PRAKOONWIT, S.; NACER, M. I. Comparative analysis using supervised learning methods for anti-money laundering in bitcoin. In: *Proceedings of the 2020 5th International Conference on Machine Learning Technologies*. ACM, 2020. p. 11–17. Disponível em: https://doi.org/10.1145/3409073.3409078.

ALTMAN, E. et al. *Realistic Synthetic Financial Transactions for Anti-Money Laundering Models*. 2023. 29851-29874 p. Datasets and Benchmarks Track, NeurIPS. Disponível em: https://doi.org/10.52202/075280-1300.

BAIGABYL, R.; NUGUMANOVA, A.; SODNOMOVA, M. Using graph centrality metrics for detection of suspicious transactions. *Scientific Journal of Astana IT University*, v. 22, p. 134–152, 2025. Disponível em: https://doi.org/10.37943/22zski6025.

BARABÁSI, A.-L. *Network Science*. Cambridge: Cambridge University Press, 2016.

BISHOP, C. M. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.

Chainalysis. *The Chainalysis 2025 Crypto Crime Report*. [*S.l.*: *s.n.*], 2025.

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York, NY, USA: Association for Computing Machinery, 2016. (KDD '16), p. 785–794. ISBN 9781450342322. Disponível em: https://doi.org/10.1145/2939672.2939785.

CHENG, D.; ZOU, Y.; XIANG, S. Graph neural networks for financial fraud detection: a review. *Frontiers of Computer Science*, Springer, v. 19, n. 9, p. 199609, 2025. Disponível em: https://doi.org/10.1007/s11704-024-40474-y.

Conselho de Controle de Atividades Financeiras. *Cartilha do COAF: Prevenção à Lavagem de Dinheiro e ao Financiamento do Terrorismo*. Brasília, DF, 2021. Disponível em: https://www.gov.br/coaf.

CONTE, A.; RUCCI, D. Are k-cores meaningful for temporal graph analysis? In: ACM. *Proceedings of the 39th ACM/SIGAPP Symposium On Applied Computing (SAC)*. 2024. p. 1453–1460. Disponível em: https://doi.org/10.1145/3605098.3635959.

DIETTERICH, T. G. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, MIT Press, v. 10, n. 7, p. 1895–1923, 1998.

DONG, X. et al. Spacegnn: Multi-space graph neural network for node anomaly detection with extremely limited labels. In: *International Conference on Learning Representations (ICLR)*. [*s.n.*], 2025. v. 39, n. 11, p. 12112–12120. Disponível em: https://doi.org/10.1609/aaai.v39i11.33319.

DUMITRESCU, B.; BĂLTOIU, A.; BUDULAN, Ş. Anomaly detection in graphs of bank transactions for anti money laundering applications. *IEEE Access*, IEEE, v. 10, p. 47699–47711, 2022. Disponível em: https://doi.org/10.1109/access.2022.3170467.

EL-KILANY, A.; AYOUB, A. M.; KADI, H. M. E. Detecting suspicious customers in money laundering activities using weighted hits algorithm. In: IEEE. *2024 5th International Conference on Artificial Intelligence, Robotics and Control (AIRC)*. 2024. p. 112–117. Disponível em: https://doi.org/10.1109/airc61399.2024.10672043.

FATF; Egmont Group. *Concealment of Beneficial Ownership*. Paris, France: [*s.n.*], 2023. 143-199 p. Disponível em: https://doi.org/10.1515/9783110985108-005.

FAWCETT, T. An introduction to roc analysis. *Pattern Recognition Letters*, Elsevier, v. 27, n. 8, p. 861–874, 2006.

FREEMAN, L. C. A set of measures of centrality based on betweenness. *Sociometry*, JSTOR, v. 40, n. 1, p. 35–41, 1977.

HAGBERG, A. A.; SCHULT, D. A.; SWART, P. J. Exploring network structure, dynamics, and function using networkx. In: *Proceedings of the 7th Python in Science Conference (SciPy)*. [*S.l.*: *s.n.*], 2008. p. 11–15.

JAPKOWICZ, N.; SHAH, M. *Evaluating Learning Algorithms: A Classification Perspective*. Cambridge: Cambridge University Press, 2011.

JENSEN, R. I. T.; IOSIFIDIS, A. Fighting money laundering with statistics and machine learning. *IEEE Access*, IEEE, v. 11, p. 8889–8903, 2023. Disponível em: https://doi.org/10.1109/access.2023.3239549.

KAR, D. *Brazil: Capital Flight, Illicit Flows, and Macroeconomic Crises, 1960-2012*. Washington, DC: [*s.n.*], 2014.

KARIM, M. R. et al. Scalable semi-supervised graph learning techniques for anti money laundering. *IEEE Access*, IEEE, v. 12, p. 50012–50029, 2024. Disponível em: https://doi.org/10.1109/access.2024.3383784.

KLEINBERG, J. M. Authoritative sources in a hyperlinked environment. *Journal of the ACM (JACM)*, ACM New York, NY, USA, v. 46, n. 5, p. 604–632, 1999.

LIU, K. et al. Bond: Benchmarking unsupervised outlier node detection on static attributed graphs. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [*s.n.*], 2022. p. 27021–27035. Disponível em: https://doi.org/10.52202/068431-1959.

LIU, X.; CHENG, H.-M.; ZHANG, Z.-Y. Evaluation of community detection methods. *IEEE Transactions on Knowledge and Data Engineering*, IEEE, p. 1–1, 2019. Disponível em: https://doi.org/10.1109/tkde.2019.2911943.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [*S.l.*: *s.n.*], 2017. v. 30, p. 4765–4774.

MITCHELL, C.; AGRAWAL, R.; PARKER, J. The effectiveness of edge centrality measures for anomaly detection. In: IEEE. *2019 IEEE International Conference on Big Data (Big Data)*. 2019. p. 5022–5027. Disponível em: https://doi.org/10.1109/bigdata47090.2019.9006468.

NEWMAN, M. E. J.; GIRVAN, M. Finding and evaluating community structure in networks. *Physical Review E*, APS, v. 69, n. 2, p. 026113, 2004.

OLIVEIRA, R. M. A.; SANT'ANNA, A. M. O.; FERREIRA, P. H. Complex networks-based anomaly detection for financial transactions in anti-money laundering. *Forensic Science International: Digital Investigation*, Elsevier, v. 55, p. 302005, 2025. Disponível em: https://doi.org/10.1016/j.fsidi.2025.302005.

PAGE, L. et al. *The PageRank Citation Ranking: Bringing Order to the Web*. [*S.l.*: *s.n.*], 1999.

RAASVELDT, M.; MÜHLEISEN, H. Duckdb: an embeddable analytical database. In: *Proceedings of the 2019 International Conference on Management of Data*. [*S.l.*: *s.n.*], 2019. p. 1981–1984.

RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. "why should i trust you?": Explaining the predictions of any classifier. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. [*S.l.*: *s.n.*], 2016. p. 1135–1144.

RIONDATO, M.; KORNAROPOULOS, E. M. Fast approximation of betweenness centrality through sampling. *Data Mining and Knowledge Discovery*, Springer, v. 30, n. 2, p. 438–475, 2014. Disponível em: https://doi.org/10.1145/2556195.2556224.

SHIN, K.; ELIASSI-RAD, T.; FALOUTSOS, C. Corescope: Graph mining using k-core analysis—patterns, anomalies and algorithms. In: IEEE. *2016 IEEE 16th International Conference on Data Mining (ICDM)*. 2016. p. 469–478. Disponível em: https://doi.org/10.1109/icdm.2016.0058.

SHIN, K.; ELIASSI-RAD, T.; FALOUTSOS, C. Patterns and anomalies in k-cores of real-world graphs with applications. *Knowledge and Information Systems*, Springer, v. 54, n. 3, p. 677–710, 2017. Disponível em: https://doi.org/10.1007/s10115-017-1077-6.

SHUKLA, S.; JAISWAL, T.; PARMAR, S. A smote-based xgboost model for effective money laundering transaction detection using synthetic data. In: IEEE. *2025 IEEE International Conference on Advances in Computing Research On Science Engineering and Technology (ACROSET)*. 2025. p. 1–7. Disponível em: https://doi.org/10.1109/acroset66531.2025.11280778.

SIZAN, M. M. H. et al. Machine learning-based unsupervised ensemble approach for detecting new money laundering typologies in transaction graphs. *International Journal of Applied Mathematics*, v. 38, n. 2s, p. 351–374, 2025. Disponível em: https://doi.org/10.12732/ijam.v38i2s.88.

TIWARI, M.; GEPP, A.; KUMAR, K. A review of money laundering literature: The state of research in key areas. *Pacific Accounting Review*, Emerald Publishing Limited, v. 32, n. 2, p. 271–303, 2020. Disponível em: https://doi.org/10.1108/par-06-2019-0065.

TRAAG, V. A.; WALTMAN, L.; ECK, N. J. van. From louvain to leiden: guaranteeing well-connected communities. *Scientific reports*, Nature Publishing Group, v. 9, n. 1, p. 1–12, 2019. Disponível em: https://doi.org/10.1038/s41598-019-41695-z.

United Nations Office on Drugs and Crime. *Estimating Illicit Financial Flows Resulting from Drug Trafficking and Other Transnational Organized Crimes*. Vienna: [*s.n.*], 2011. Disponível em: https://www.unodc.org/documents/data-and-analysis/Studies/Illicit_financial_flows_2011_web.pdf. Acesso em: 26 mar. 2026.

VASSALLO, D.; VELLA, V.; ELLUL, J. Application of gradient boosting algorithms for anti-money laundering in cryptocurrencies. *SN Computer Science*, Springer, v. 2, n. 143, p. 143, 2021. Disponível em: https://doi.org/10.1007/s42979-021-00558-z.

VILELLA, S. et al. Weirdnodes: centrality based anomaly detection on temporal networks for the anti-financial crime domain. *Applied Network Science*, Springer, v. 10, n. 14, p. 14, 2025. Disponível em: https://doi.org/10.1007/s41109-025-00702-1.

VinciWorks. *A Guide To Money Laundering Compliance In Brazil*. 2014. 135-143 p. Disponível em: https://vinciworks.com/blog/a-guide-to-money-laundering-compliance-in-brazil.

WEBER, M. et al. Anti-money laundering in bitcoin: Experimenting with graph convolutional networks for financial forensics. *arXiv preprint arXiv:1907.12222*, 2019.

Working Group for National Risk Assessment. *National Risk Assessment: Brazil 2021*. [*s.n.*], 2023. v. 28, n. 6, 1601-1606 p. Disponível em: https://doi.org/10.1590/1413-81232023286.01892023.