Universidade do Estado do Rio de Janeiro
Centro setorial
Unidade Patrono

Pedro Caetano Pires

Modelo de dissertação e tese (modelo.tex: v.2026.03, repUERJ.cls: v.2026.03, repUERJformat.sty: v.2026.03, repUERJpseudocode.sty: v.2025.07a)

Rio de Janeiro
2026

Pedro Caetano Pires

Modelo de dissertação e tese (modelo.tex: v.2026.03, repUERJ.cls: v.2026.03, repUERJformat.sty: v.2026.03, repUERJpseudocode.sty: v.2025.07a)

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Ciência da Computação, ao Unidade Patrono, da Universidade do Estado do Rio de Janeiro.

Orientador: Prof. D.Sc. Bruno Porto Masquio

Rio de Janeiro

2026

CATALOGAÇÃO NA FONTE
UERJ / REDE SIRIUS / BIBLIOTECA CTC/D

ISTO É APENAS DEMONSTRATIVO
DEVE SER SUBSTITUÍDO PELA FICHA CATALOGRÁFICA QUE A BIBLIOTECA PROVIDENCIAR.

D979 Caetano Pires, Pedro
Modelo de dissertação e tese (modelo.tex: v.2026.03, repUERJ.cls: v.2026.03, repUERJformat.sty: v.2026.03, repUERJpseudocode.sty: v.2025.07a) / Pedro Caetano Pires. – Rio de Janeiro, 2026-
30 f.

Orientador: Prof. D.Sc. Bruno Porto Masquio
Trabalho de Conclusão de Curso (Graduação) – Universidade do Estado do Rio de Janeiro, Unidade, Unidade Patrono, 2026.

1. Primeira palavra-chave;. 2. Segunda palavra-chave;. 3. Terceira palavra-chave.. I. Prof. D.Sc. Bruno Porto Masquio. II. Universidade do Estado do Rio de Janeiro. III. Unidade. IV. Título

CDU 02:141:005.7

RASCUNHO

Autorizo, apenas para fins acadêmicos e científicos, a reprodução total ou parcial desta trabalho de conclusão de curso, desde que citada a fonte.

Assinatura Data

Pedro Caetano Pires

Modelo de dissertação e tese (modelo.tex: v.2026.03, repUERJ.cls: v.2026.03, repUERJformat.sty: v.2026.03, repUERJpseudocode.sty: v.2025.07a)

Trabalho de Conclusão de Curso apresentado, como requisito parcial para obtenção do título de Graduado em Ciência da Computação, ao Unidade Patrono, da Universidade do Estado do Rio de Janeiro.

Aprovada em dia de mês de 2026.
Banca Examinadora:

Prof. D.Sc. Bruno Porto Masquio (Orientador)
Unidade – UERJ

Cargo Título Nome Completo
Instituição por extenso

Cargo Título Nome Completo
Instituição por extenso

Cargo Título Nome Completo
Unidade Patrono – UERJ

Cargo Título Nome Completo
Unidade Patrono – UERJ

Cargo Título Nome Completo
Unidade Patrono – UERJ

Rio de Janeiro
2026

DEDICATÓRIA

Conforme UERJ (2012, p.38), é um elemento opcional. [...] O texto da dedicatória deve estar localizado na parte inferior da folha, seguindo as regras gerais de apresentação gráfica.

AGRADECIMENTOS

Segundo UERJ (2012, p.39), é um elemento opcional. O texto dos agradecimentos deve ser separado do título por duas linhas em branco com espaçamento 1,5 e digitado de acordo as regras gerais de apresentação gráfica. Se houver necessidade, o texto pode continuar nas folhas seguintes, sem incluir a palavra Agradecimentos.

Epígrafe – elemento opcional (Cf. UERJ, 2012, p.40).
É uma citação sem aspas – em fonte 12, estilo normal, com espaço 1,5 – seguida da indicação de autoria, grafada em fonte 12 e em itálico.
O texto deve estar localizado no terço inferior da folha, com o alinhamento livre, necessário à epígrafe.
É um pequeno texto em prosa ou verso, com uma citação, pensamento ou provérbio.
Tem por função introduzir o leitor ao tema, servir de reflexão ou inspiração, e estabelecer uma conexão com o conteúdo da monografia.

Texto da epígrafe
Pensamento, reflexão
autor

RESUMO

CAETANO PIRES, P.C.P. **Modelo de dissertação e tese (modelo.tex: v.2026.03, repUERJ.cls: v.2026.03, repUERJformat.sty: v.2026.03, repUERJpseudocode.sty: v.2025.07a)**. 2026. 30 f. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) – Unidade Patrono, Universidade do Estado do Rio de Janeiro, Rio de Janeiro, 2026.

Conforme UERJ (2012, p.42), é elemento obrigatório. Consiste na apresentação sucinta dos pontos relevantes do texto, em um único parágrafo. O resumo deve conter entre 150 e 500 palavras e fornecer uma visão rápida e clara dos objetivos, da metodologia, dos resultados e das conclusões do trabalho. Na elaboração do resumo, deve-se usar o verbo na voz ativa, na terceira pessoa do singular.

Palavras-chave: Primeira palavra-chave; Segunda palavra-chave; Terceira palavra-chave.

ABSTRACT

CAETANO PIRES, P.C.P. **Título do trabalho em inglês**. 2026. 30 f. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) – Unidade Patrono, Universidade do Estado do Rio de Janeiro, Rio de Janeiro, 2026.

De acordo com UERJ (2012, p.44), consiste em uma tradução do resumo em português para uma língua estrangeira (em inglês, ABSTRACT; em espanhol, RESUMEN; em francês, RÉSUMÉ), em um único parágrafo, seguido das palavras–chave representativas do conteúdo do trabalho, na língua estrangeira escolhida. O resumo em outra língua também é precedido pela referência do trabalho, substituindo-se o título em português pelo título na língua estrangeira adotada. No caso de teses, é possível incluir dois resumos em língua estrangeira. A apresentação gráfica e a ordem dos elementos seguem a mesma orientação do resumo em português.

Keywords: First keyword; Second keyword; Third keyword.

LIST OF PICTURES

LISTA DE TABELAS

Tabela 1 - Resumo das variações do *dataset* AMLworld 22

LISTA DE ALGORITMOS

LISTA DE ABREVIATURAS E SIGLAS

sigla 1	por extenso
sigla 2	por extenso
sigla 3	por extenso

É elemento opcional. Os elementos dessa lista são descritos em ordem alfabética, seguidos de seu significado grafado por extenso. Recomenda-se a elaboração dessa lista quando existirem abreviaturas e siglas específicas da área e incluídas no trabalho. Ressalta-se que, uma vez formada, a lista deverá conter todas as abreviaturas e siglas que aparecerem no trabalho. (UERJ, 2012, p.51)

LISTA DE SÍMBOLOS

*simbolo*1	significado e/ou valor
*simbolo*2	significado e/ou valor
*simbolo*3	significado e/ou valor

É elemento opcional. Os elementos dessa lista são descritos na mesma ordem em que aparecem no texto, seguidos de seu significado grafado por extenso. (UERJ, 2012, p.52)

SUMÁRIO

	INTRODUÇÃO	14
1	**FUNDAMENTAÇÃO TEÓRICA**	16
1.1	**Métricas de Avaliação**	16
1.1.1	Matriz de Confusão	16
1.1.2	Métricas de Desempenho e o Problema do Desbalanceamento	16
1.2	**Teoria dos Grafos**	17
1.2.1	Grafos Temporais	18
1.2.2	Atributos Topológicos	18
1.2.2.1	Métricas de Centralidade e Coesão	19
1.2.2.2	Detecção de Comunidades	20
1.2.2.3	Padrões de Vizinhança e *Motifs*	21
2	**METODOLOGIA E DESENVOLVIMENTO**	22
2.1	**Base de Dados**	22
2.1.1	Pré-processamento e Padronização dos Dados	23
2.2	**Modelagem da Janela Deslizante e Agregação de Arestas**	23
2.3	**Engenharia de *Features* Topológicas**	25
2.3.1	Métricas de Centralidade e Coesão	25
2.3.2	Detecção de Comunidades (Leiden)	26
2.3.3	Padrões de Vizinhança, Agregação e *Motifs*	26
2.4	**Arquitetura *Two-Stage Cascade* com XGBoost**	27
2.4.1	Estudo de Ablação e Otimização (*SHAP-RFE*)	27
3	**CONCLUSÃO**	28
	REFERÊNCIAS BIBLIOGRÁFICAS	29

INTRODUÇÃO

Texto da epígrafe *in locu* (opcional).
Autor

A lavagem de dinheiro consiste em reinserir na economia recursos obtidos de forma ilícita, ocultando sua origem. Segundo United Nations Office on Drugs and Crime (2011), esse crime movimenta entre 2% e 5% do PIB mundial por ano, o que exige das instituições financeiras sistemas de monitoramento em larga escala. Tradicionalmente, a detecção de anomalias em AML (*Anti-Money Laundering*) baseia-se em heurísticas e regras estáticas, centradas em limites de valor e frequência transacional. Essa abordagem tende a gerar altas taxas de falsos positivos, sobrecarregar equipes de *compliance* e falhar na identificação de tipologias criminosas mais recentes, nas quais os fraudadores fragmentam os valores em múltiplas contas e camadas de ofuscação (JENSEN; IOSIFIDIS, 2023).

Como forma de mascarar suas atividades, agentes ilícitos realizam suas operações explorando propriedades topológicas específicas, como *smurfing*, ciclos de transferência e nós de dispersão, para cortar o rastro do dinheiro (CHENG; ZOU; XIANG, 2025). Enquanto a análise tabular tradicional avalia o comportamento de uma conta de forma isolada, a aplicação de Ciência de Dados de Grafos permite extrair métricas de centralidade, detecção de comunidades, informações topológicas e anomalias de vizinhança que capturam dados sobre o comportamento dos participantes da rede (BAIGABYL; NUGUMANOVA; SODNOMOVA, 2025).

Algoritmos de *Gradient Boosting*, como o XGBoost, são amplamente utilizados para análise de dados estruturados devido à eficiência computacional e robustez no tratamento do desbalanceamento extremo de classes, típico da detecção de fraudes (ALARAB; PRAKOONWIT; NACER, 2020). No entanto, o XGBoost puro não processa estruturas relacionais nativamente: existe a necessidade de isolar e quantificar o ganho real de performance que as *features* baseadas em grafos injetam nesses modelos tabulares (KARIM et al., 2024). Além disso, é necessário estabelecer se a complexidade extra de treinar um modelo de *Machine Learning* se justifica frente ao uso direto de algoritmos de grafos isolados atuando como detectores de fraude.

O objetivo principal deste trabalho é investigar e quantificar o impacto da adição de variáveis topológicas de grafos na eficácia do algoritmo XGBoost para a detecção de entidades participantes em esquemas de lavagem de dinheiro, utilizando o *dataset* AMLworld (ALTMAN et al., 2023).

Como objetivos específicos, definem-se:

- Modelar o *dataset* transacional como uma rede temporal e extrair atributos topológicos, preservando a cronologia estrita através de janelas temporais para impedir o

vazamento de dados (*data leakage*).

- Avaliar a capacidade preditiva de algoritmos de grafos atuando de forma isolada na identificação de entidades fraudulentas.
- Implementar uma arquitetura *Two-Stage Cascade* baseada em XGBoost, utilizando pesagem algorítmica fracionária para mitigar o alto volume de falsos positivos inerente a cenários de detecção de anomalias.
- Conduzir um estudo de ablação sob validação *forward-chaining*, comparando estatisticamente o impacto no desempenho gerado pela adição das *features* topológicas em relação a um modelo de base puramente comportamental.
- Otimizar a eficiência computacional do modelo para *deploy* operacional através de um método de poda de atributos combinando filtros de colinearidade e eliminação recursiva guiada por SHAP (*SHAP-RFE*).
- Mensurar o impacto operacional e quantificar a captura real de infratores através de diferentes métricas de avaliação de desempenho.

1 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, são apresentadas as principais métricas de avaliação de modelos de classificação aplicados à detecção de fraudes no contexto de lavagem de dinheiro.

1.1 Métricas de Avaliação

A avaliação de modelos preditivos no contexto de *Anti-Money Laundering* (AML) exige métricas robustas ao desbalanceamento extremo de classes, uma vez que a proporção de transações ilícitas é tipicamente inferior a 1% do volume total (SHUKLA; JAISWAL; PARMAR, 2025).

1.1.1 Matriz de Confusão

Em problemas de classificação binária, cada entidade é rotulada como fraude (classe positiva) ou não fraude (classe negativa). A partir das previsões do modelo, obtêm-se quatro resultados possíveis que compõem a matriz de confusão:

- *True Positive* (TP): a entidade era fraudulenta e foi corretamente classificada;
- *True Negative* (TN): a entidade não era fraudulenta e foi corretamente classificada;
- *False Positive* (FP): a entidade não era fraudulenta, mas o modelo gerou um alerta falso;
- *False Negative* (FN): a entidade era fraudulenta e não foi detectada.

1.1.2 Métricas de Desempenho e o Problema do Desbalanceamento

O *Recall* (Sensibilidade) mede a capacidade de recuperar exemplos positivos, indicando a proporção de fraudadores reais que foram efetivamente detectados:

$$\text{Recall} = \frac{TP}{TP + FN} \tag{1}$$

A *Precision* mede a exatidão dos alertas gerados, ou seja, a proporção de predições

de fraude que estavam corretas:

$$\text{Precision} = \frac{TP}{TP + FP} \tag{2}$$

O *F1-score* combina ambas através de uma média harmônica, oferecendo uma visão equilibrada do modelo (ALARAB; PRAKOONWIT; NACER, 2020):

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{3}$$

Embora a *Accuracy* (Acurácia) meça a proporção total de classificações corretas, a sua utilização isolada em cenários de fraude pode levar à interpretações errôneas: um modelo que preveja a classe majoritária (não-fraude) alcançará uma acurácia próxima de 100%, falhando completamente no seu objetivo (VASSALLO; VELLA; ELLUL, 2021).

Por esta razão, a literatura privilegia métricas que avaliam o poder de separação entre classes em diferentes limiares. A *ROC-AUC* (*Receiver Operating Characteristic Area Under the Curve*) relaciona a taxa de verdadeiros positivos (TPR) com a taxa de falsos positivos (FPR). No entanto, em cenários de desbalanceamento severo, a *AUPRC* (Precisão-Recall Area Under the Curve) é considerada mais informativa, pois foca o desempenho estritamente no impacto sobre a classe positiva (LIU et al., 2022).

Para efeitos de implantação em ambiente real, as equipes de *compliance* possuem capacidade finita de investigação diária. Assim, a *Precision@k* avalia a fração de verdadeiros positivos entre os k primeiros exemplos com maior probabilidade de fraude ranqueados pelo modelo, refletindo a eficácia operacional do sistema (KARIM et al., 2024).

1.2 Teoria dos Grafos

A Teoria dos Grafos fornece ferramentas matemáticas capazes de modelar interações complexas do mundo real no formato de vértices e arestas. No contexto de transações financeiras, as interações não ocorrem como eventos estáticos e isolados, mas sim como múltiplos fluxos paralelos que variam no tempo. Por isso, a rede é modelada como um grafo direcionado, ponderado por múltiplos atributos e subdividido em janelas temporais (OLIVEIRA; SANT'ANNA; FERREIRA, 2025).

Formalmente, define-se este grafo como $G = (V, E)$, onde V representa o conjunto de vértices (entidades ou contas bancárias) e E representa o conjunto de arestas direcionadas (fluxos financeiros agregados).

Diferentemente de abordagens tradicionais que utilizam um único peso ou transações individuais, a agregação das transações entre duas entidades u e v dentro de uma janela temporal resulta em uma aresta direcionada $e = (u, v) \in E$ que possui dois atribu-

tos quantitativos extraídos na etapa de consolidação dos dados:

- w_{vol}: o volume financeiro transferido do vértice de origem u para o vértice de destino v no período.
- w_{count}: a quantidade de transações realizadas de u para v no período.

A representação de múltiplos pesos nas arestas permite a extração de métricas de centralidade relacionadas à diferentes comportamentos. Neste trabalho, algoritmos como o *PageRank* são calculados em múltiplas formulações independentes, utilizando tanto a matriz de adjacência ponderada pelo volume (w_{vol}) quanto a ponderada pela frequência transacional (w_{count}). Essa abordagem permite que o modelo identifique não apenas a concentração de grandes volumes de capital, mas também o comportamento de dispersão e estruturação repetitiva (como o *smurfing*), que muitas vezes envolve valores financeiros menores, mas com alto número de operações (VILELLA et al., 2025).

1.2.1 Grafos Temporais

A análise estática de um grafo financeiro, a qual agrega todas as transações em uma única topologia atemporal, introduz vazamento de dados (*data leakage*) ao permitir que eventos futuros influenciem a extração de características de eventos passados. Para preservar a causalidade estrita, o sistema deve ser modelado como um grafo temporal estruturado em janelas cronológicas (SIZAN et al., 2025).

Matematicamente, a rede temporal é dividida em uma sequência de grafos instantâneos (ou *snapshots*) $G = \{G_1, G_2, \ldots, G_T\}$. Cada grafo $G_i = (V_i, E_i)$ é construído a partir de uma janela deslizante (*sliding window*) de tamanho fixo Δt, que avança progressivamente com um passo temporal definido (*stride*). A extração de propriedades topológicas para avaliar um vértice na janela i restringe-se exclusivamente às arestas E_i observadas dentro desse intervalo específico. Essa delimitação garante que o cálculo das métricas não seja contaminado por transações fora do escopo temporal analisado, operando sob as mesmas restrições informacionais de um ambiente de produção real (SIZAN et al., 2025).

1.2.2 Atributos Topológicos

A topologia local e global da rede fornece sinais preditivos estruturais que são invisíveis à análise comportamental isolada de um vértice. Os atributos extraídos dividem-se em três categorias principais:

1.2.2.1 Métricas de Centralidade e Coesão

As métricas de centralidade quantificam a importância ou influência de um vértice na rede, enquanto as de coesão avaliam seu aninhamento estrutural.

- **Grau (*Degree*):** Subdividido em grau de entrada (*in-degree*) e de saída (*out-degree*), mede o número de conexões distintas de um nó. Matematicamente, dado a matriz de adjacência A do grafo, os graus de um vértice i são definidos como:

$$k_i^{in} = \sum_{j \in V} A_{ji}, \quad k_i^{out} = \sum_{j \in V} A_{ij} \tag{4}$$

  Contas utilizadas como vértices de passagem ou que possuem uma concentração alta de fundos ilícitos exibem graus altos.

- **Algoritmo HITS (*Hyperlink-Induced Topic Search*):** Atribui a cada vértice uma pontuação de *Hub* (h) e uma pontuação de *Authority* (a). Estas pontuações são atualizadas iterativamente através da relação mutuamente recursiva:

$$h(u) = \sum_{v \in N_{out}(u)} a(v), \quad a(v) = \sum_{u \in N_{in}(v)} h(u) \tag{5}$$

  onde $N_{out}(u)$ e $N_{in}(v)$ representam os conjuntos de vizinhos de saída de u e de entrada de v, respectivamente.

- **Centralidade de Intermediação (*Betweenness Centrality*):** Mede a frequência com que um vértice aparece nos caminhos mais curtos entre outros pares de nós. A centralidade do vértice v é dada por:

$$C_B(v) = \sum_{s \neq v \neq t \in V} \frac{\sigma_{st}(v)}{\sigma_{st}} \tag{6}$$

  Onde σ_{st} é o número total de caminhos mais curtos de s para t, e $\sigma_{st}(v)$ é o número desses caminhos que passam obrigatoriamente por v. Na lavagem de dinheiro, contas de ofuscação atuam frequentemente como pontes entre diferentes aglomerados da rede.

- ***PageRank* de Múltiplas Profundidades:** Processado com diferentes fatores de amortecimento (α). A pontuação de um vértice u é calculada iterativamente por:

$$PR(u) = \frac{1-\alpha}{N} + \alpha \sum_{v \in B_u} \frac{PR(v)}{L(v)} \tag{7}$$

  Sendo N o número total de vértices, B_u o conjunto de vértices que apontam para u, e $L(v)$ o número de links de saída do vértice v. A formulação com $\alpha = 0.85$ (*deep*)

permite ao algoritmo encontrar padrões mais longos na rede, enquanto $\alpha = 0.75$ (*shallow*) foca na influência local, otimizando a detecção de anéis de lavagem curtos e rápidos.

- **Decomposição *K-Core*:** Avalia a profundidade de aninhamento de uma conta na rede. Dado um grafo $G = (V, E)$, um subgrafo induzido $H = (V_k, E_k)$ é definido como um *k-core* se for o subgrafo maximal onde o grau de todo vértice $v \in V_k$, restrito a H, é maior ou igual a k:

$$\forall v \in V_k, \quad d_H(v) \geq k \tag{8}$$

A métrica individual extraída para o modelo preditivo é o valor de *coreness* (ou número *core*) de um vértice, denotado por $c(v)$. Este valor representa o grau máximo k para o qual o vértice v ainda pertence a um *k-core*:

$$c(v) = \max\{k \mid v \in V_k\} \tag{9}$$

Vértices com altos valores de $c(v)$ pertencem ao núcleo denso e estruturalmente coeso do grafo. No contexto financeiro, isso frequentemente está associado a contas controladoras que orquestram e centralizam a fraude, sendo muito mais difíceis de desmantelar do que contas de periferia.

1.2.2.2 Detecção de Comunidades

A detecção de comunidades visa particionar o grafo em subconjuntos de vértices densamente conectados internamente e esparsamente conectados com o restante da rede.

- **Algoritmo Leiden:** Utilizado pela sua eficiência e garantia de conectividade interna. O algoritmo busca particionar a rede de modo a maximizar a modularidade (Q), que compara a densidade de arestas dentro das comunidades com a densidade esperada em um grafo aleatório:

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j) \tag{10}$$

Onde A_{ij} representa o peso da aresta entre i e j, k_i é o grau do vértice i, m é a soma de todos os pesos das arestas e a função indicadora $\delta(c_i, c_j)$ assume valor 1 se i e j pertencem à mesma comunidade e 0 caso contrário. Fundamentalmente, a modularidade das macro e microcomunidades quantifica o quão isolado e compartimentado está um anel financeiro ilícito em relação à economia lícita adjacente.

1.2.2.3 Padrões de Vizinhança e *Motifs*

A extração da topologia de entorno e de subgrafos frequentes (*motifs*) captura a mecânica exata das tipologias de fraude.

- **Atributos de *Egonet* (Rede de Ego):** Avaliam a vizinhança imediata (1-hop) do vértice. A extração da densidade da egorrede, quantidade de nós, arestas e peso total consolidado medem a coesão local ao redor da entidade. O coeficiente de agrupamento (*local clustering coefficient*) e a contagem de triângulos refinam essa análise validando a interconectividade dos vizinhos.

- **Padrões Direcionais e *Motifs* Complexos:** A contagem de estruturas simples de dispersão (*fan-out*) e concentração (*fan-in*) é expandida para *motifs* compostos, como o *scatter-gather* e o *gather-scatter*. Estas topologias são as representações matemáticas exatas das fases de pulverização (*layering*) e integração (*integration*) de recursos. A contagem de ciclos (*cycle count*) mapeia as trajetórias circulares utilizadas para criar a ilusão de atividade econômica legítima.

- **Agregação de Vizinhança e Dinâmica Temporal:** Sinais de fraude propagam-se topologicamente. O comportamento dos sucessores imediatos (volume médio e máximo transferido por eles) sinaliza o destino do capital pós-transferência. Adicionalmente, *motifs* temporais (*temporal fan-out* e *temporal fan-in*) medem a estruturação de fluxos de forma estritamente cronológica e agressiva, capturando operações que ocorrem em frações de tempo reduzidas, complementando a abstração estática da janela temporal.

2 METODOLOGIA E DESENVOLVIMENTO

Texto da epígrafe *in locu* (opcional).
Autor

Este capítulo detalha a metodologia proposta para investigar e quantificar o impacto da adição de variáveis topológicas na detecção de esquemas de lavagem de dinheiro. O desenvolvimento do trabalho é estruturado de forma a replicar os desafios de um ambiente de *compliance* do mundo real, considerando a avaliação cronológica e eficiência computacional.

2.1 Base de Dados

Para o treinamento e a validação da arquitetura proposta, este estudo utiliza o *dataset* sintético AMLworld (ALTMAN et al., 2023). A escolha por uma base de dados sintética justifica-se pelas restrições de privacidade e confidencialidade que limitam o acesso público a dados transacionais bancários reais. Além disso, há o problema de que parte das fraudes que ocorrem no mundo real passam desapercebidas pelas autoridades, o que torna as bases de dados baseadas em transações reais deficitárias. O AMLworld foi projetado especificamente para simular padrões de lavagem de dinheiro em larga escala e oferecer rótulos confiáveis para transações lícitas e ilícitas, o que viabiliza o treinamento supervisionado.

A base de dados oferece, ao todo, seis variações que combinam escala (*Small*, *Medium* e *Large*) e nível de atividade ilícita (HI: *High Illicit*; LI: *Low Illicit*), conforme apresentado na Tabela 1.

Tabela 1 – Resumo das variações do *dataset* AMLworld

Métrica	**Small HI**	**Small LI**	**Medium HI**	**Medium LI**	**Large HI**	**Large LI**
Intervalo de datas (2022)	Sep 1–10	Sep 1–10	Sep 1–16	Sep 1–16	Aug 1–Nov 5	Aug 1–Nov 5
Dias cobertos	10	10	16	16	97	97
Contas bancárias	515K	705K	2,077K	2,028K	2,116K	2,064K
Transações	5M	7M	32M	31M	180M	176M
Transações de lavagem	5,1K	4,0K	35K	16K	223K	100K
Taxa de lavagem (1 em N transações)	981	1,942	905	1,948	807	1,750
Tamanho (GB)	0,5	0,6	3	3	17	16

Neste trabalho, foram utilizados os *datasets* HI Small e HI Medium.

2.1.1 Pré-processamento e Padronização dos Dados

Devido ao volume massivo de registros gerados pelas variações do *dataset* AMLworld (alcançando até 180 milhões de transações na variação *Large*), o tratamento da base bruta exigiu estratégias específicas de engenharia de dados.

A leitura do arquivo original em formato de texto (*CSV*) foi implementada em blocos de 3 milhões de linhas utilizando a biblioteca Pandas em Python (versão 3.12)[1],. Durante a iteração, os cabeçalhos foram padronizados, as datas convertidas para o formato ISO 8601 e, para garantir viabilidade computacional no processamento subsequente, os dados foram persistidos no formato colunar Apache Parquet [2]. Esta conversão reduziu drasticamente o espaço de armazenamento e otimizou a velocidade de leitura (*I/O*) nas etapas de agregação.

Adicionalmente, o *dataset* simula um ambiente global, contendo transações realizadas em 14 moedas fiduciárias distintas (incluindo Euro, Libra, Real e Iene), bem como em criptomoedas (Bitcoin). A modelagem de um grafo financeiro ponderado exige que todas as arestas utilizem a mesma escala de grandeza. Caso contrário, a soma direta de valores nominais distorceria os algoritmos de centralidade.

Para resolver este problema, desenvolveu-se uma etapa de padronização monetária. Utilizando a API do *Yahoo Finance* (`yfinance`), foram extraídas as taxas de câmbio diárias de fechamento em relação ao Dólar Americano (USD) para todo o período de cobertura do *dataset* (agosto a novembro de 2022). Esta tabela histórica de conversão foi salva de forma independente e utilizada posteriormente para calibrar o peso financeiro (w_{vol}) de cada aresta com base na data exata da transação original, garantindo a coerência econômica da rede construída.

2.2 Modelagem da Janela Deslizante e Agregação de Arestas

Para mitigar o risco de vazamento de dados (*data leakage*) e preservar a causalidade estrita dos eventos financeiros (SIZAN et al., 2025), o fluxo de transações do *dataset* AMLworld foi processado cronologicamente como um grafo temporal.

A extração das janelas cronológicas (*snapshots*) e a agregação do grafo foram implementadas utilizando o sistema de gerenciamento de banco de dados analítico em memória DuckDB (RAASVELDT; MÜHLEISEN, 2019). A adoção do DuckDB justifica-se pela sua alta eficiência de *I/O* e otimização *multithreading* (configurado para 8 *threads* e limite

[1] Python Software Foundation. Disponível em: https://www.python.org/.

[2] Apache Parquet. Disponível em: https://parquet.apache.org/.

de memória de 6 GB) ao processar os milhões de registros transacionais armazenados no formato colunar Apache Parquet.

A definição do tamanho da janela deslizante (Δt) e do passo temporal (*stride*) baseou-se em uma etapa de otimização empírica. Foram testadas diferentes configurações com o objetivo de maximizar o desempenho preditivo (métricas de avaliação extraídas do modelo) garantindo, simultaneamente, a viabilidade computacional do processamento das métricas topológicas em um ambiente com recursos limitados de memória (8 GB de RAM).

Dentro de cada janela de 3 dias, as transações individuais (multiarestas) foram agregadas. É importante ressaltar que os vértices do grafo (V) foram modelados para representar **entidades financeiras** (indivíduos ou empresas) e não contas bancárias isoladas. Essa etapa de mapeamento (realizada através do cruzamento com o cadastro de entidades) é crucial no contexto de *Anti-Money Laundering* (AML). Frequentemente, fraudadores utilizam múltiplas contas para praticar *smurfing*) e tentar simular comportamentos normais. Com a agregação o grafo por entidade, é possível observar o fluxo real de capital.

Dessa forma, as transações ocorridas entre uma entidade de origem u e uma entidade de destino v foram consolidadas, resultando em um grafo direcionado simples onde cada aresta $e = (u, v)$ resume o fluxo financeiro do período.

Essa etapa de simplificação estrutural é necessária devido ao fato de algoritmos como o *PageRank*, *Betweenness Centrality* e os algoritmos de detecção de comunidades exigirem uma matriz de adjacência simples ponderada, não operando nativamente sobre multigrafos (BAIGABYL; NUGUMANOVA; SODNOMOVA, 2025). Ao consolidar as multiarestas em uma única aresta direcional, o modelo preserva a magnitude e a frequência do fluxo financeiro por meio dos atributos de peso, viabilizando o processamento matemático da rede (VILELLA et al., 2025).

Durante este processo de agrupamento via banco de dados (SQL), os seguintes atributos consolidados de aresta foram extraídos:

- **Volume Agregado em USD (w_{vol}):** Utilizando a tabela histórica de taxas de câmbio, combinando a moeda de pagamento e a data exata da transação original.
- **Frequência por Formato de Pagamento (w_{count}):** Além do número absoluto de transações consolidadas, a agregação também identifica a volumetria pela contagem de meios de pagamento específicos utilizados na janela (e.g., *cash*, *bitcoin*, *cheque*, *credit card* e *ACH*).

Esta agregação gerou a matriz de adjacência ponderada final do *snapshot*, a qual serviu como estrutura base para a extração computacional das *features* topológicas na etapa subsequente.

2.3 Engenharia de *Features* Topológicas

A extração de atributos topológicos foi aplicada individualmente a cada um dos grafos instantâneos (G_i) gerados na etapa anterior. Para viabilizar o processamento em tempo hábil das centenas de milhares de transações por janela, a rotina de extração foi implementada com suporte a multiprocessamento (através da biblioteca `concurrent.futures` do Python), distribuindo a carga computacional das janelas temporais de forma paralela. A base principal para o cálculo das métricas foi a biblioteca `NetworkX`, com exceção da detecção de comunidades, a qual foi implementada utilizando a biblioteca `iGraph`.

Além das heurísticas de vértice pré-calculadas na rotina de banco de dados (como uso de moedas em espécie, *bitcoin* e contagem direcional temporal), as rotinas em Python extraíram os seguintes conjuntos de atributos estruturais:

2.3.1 Métricas de Centralidade e Coesão

O cálculo exato de certas métricas de centralidade em grafos de grande escala apresenta complexidade de tempo proibitiva. Portanto, foram adotadas abordagens de otimização e parametrização específicas para o ambiente de *Big Data*:

- **Centralidade de Intermediação (*Betweenness*):** O cálculo exato do *betweenness* requer o cômputo de todos os caminhos mais curtos do grafo, o que é inviável em redes de milhões de nós. Para contornar esta limitação de *hardware*, adotou-se o método de aproximação por amostragem de vértices (RIONDATO; KORNAROPOULOS, 2016). A métrica foi calculada extraindo-se caminhos a partir de uma amostra de $k = 80$ nós sentinelas ($seed = 42$), garantindo um equilíbrio ótimo entre tempo de processamento e fidelidade estrutural.

- ***PageRank*:** A fim de capturar diferentes dinâmicas de fluxo, o *PageRank* foi instanciado em quatro variações. Em relação à profundidade, utilizou-se o fator de amortecimento (*damping factor*) tradicional $\alpha = 0.85$ (capturando difusão de longo alcance) e um fator modificado $\alpha = 0.75$ (focado em vizinhanças curtas). Ambas as profundidades foram calculadas duas vezes: uma utilizando a matriz ponderada pelo volume financeiro (w_{vol}) e outra pela contagem de transações (w_{count}). O limite de convergência foi fixado em 100 iterações.

- **Algoritmo HITS:** O processamento das pontuações de *Hub* e *Authority* foi parametrizado com um limite máximo de 500 iterações ($max_iter = 500$), garantindo a convergência mesmo em janelas temporais de altíssima densidade.

- **Decomposição *K-Core*:** Devido à exigência topológica do algoritmo, o grafo

direcionado ponderado foi primeiramente convertido para uma projeção simples não-direcionada e sem auto-laços (*self-loops*). A partir dessa projeção, extraiu-se o valor de *coreness* máximo atingido por cada entidade na referida janela temporal.

2.3.2 Detecção de Comunidades (Leiden)

Embora o `NetworkX` possua ampla gama de algoritmos de grafos, ele apresenta gargalos de performance para detecção avançada de comunidades. Por isso, a rede foi convertida para a estrutura da biblioteca `igraph`, permitindo a aplicação da biblioteca `leidenalg` (TRAAG; WALTMAN; ECK, 2019).

A otimização de modularidade foi realizada empregando o modelo *RBConfigurationVertexPartition*. Para identificar tanto as macrorredes de cooperação ilícita quanto os pequenos anéis fechados de ofuscação, o algoritmo de Leiden foi executado em duas resoluções distintas:

- **Macro-resolução:** Com parâmetro de resolução $\gamma = 1.0$.
- **Micro-resolução:** Com parâmetro de resolução $\gamma = 2.0$.

Para cada resolução, extraiu-se o tamanho da comunidade na qual o vértice foi inserido e a pontuação de modularidade local, injetando esses metadados como *features* tubulares do nó correspondente.

2.3.3 Padrões de Vizinhança, Agregação e *Motifs*

Os padrões comportamentais de vizinhança (1-salto) foram extraídos para mapear o grau de estruturação no entorno imediato das entidades financeiras (DONG et al., 2025).

- ***Egonets* e Coesão Local:** Para cada vértice, gerou-se o seu subgrafo de raio 1 (*ego graph*). A partir dele, calculou-se a densidade local, a contagem de nós periféricos e a soma do peso total circulante (*volume*). Em paralelo, calculou-se o coeficiente de agrupamento local (*local clustering coefficient*) utilizando os pesos financeiros, além da contagem de triângulos baseada na projeção não-direcionada da rede.
- **Agregação de Sucessores:** Como forma de avaliar o risco de pulverização, extraiu-se a volumetria enviada aos sucessores de cada nó. Foram calculados o grau médio da vizinhança e os volumes médio e máximo enviados aos nós destinos no *snapshot*.
- **Mapeamento de *Motifs* Complexos:** Uma rotina de busca de subgrafos isomorfos foi implementada para contar táticas explícitas de lavagem. O limiar de dispersão

e concentração (*fan-out* e *fan-in*) foi estipulado em $k \geq 5$ vizinhos, respeitando um grau máximo de 16 conexões para evitar ruído de contas institucionais gigantes. Com base nessa filtragem, calculou-se as ocorrências encadeadas de *scatter-gather* e *gather-scatter*. Adicionalmente, buscou-se a ocorrência de ciclos simples fechados limitados a até 5 saltos de distância ($length_bound = 5$), aplicando-se uma trava computacional máxima de 1.000 ciclos processados por nó ($max_cycles = 1000$).

Ao término dessa bateria de extração estrutural, as tabelas tabulares isoladas de cada *chunk* foram concatenadas pelo `DuckDB`, construindo o *dataset* final enriquecido (*sliding_window_features.parquet*) que servirá de matriz de entrada (X) para o modelo preditivo.

2.4 Arquitetura *Two-Stage Cascade* com XGBoost

2.4.1 Estudo de Ablação e Otimização (*SHAP-RFE*)

3 CONCLUSÃO

REFERÊNCIAS BIBLIOGRÁFICAS

ALARAB, I.; PRAKOONWIT, S.; NACER, M. I. Comparative analysis using supervised learning methods for anti-money laundering in bitcoin. In: *Proceedings of the 2020 5th International Conference on Machine Learning Technologies*. [*S.l.*]: ACM, 2020.

ALTMAN, E. et al. *Realistic Synthetic Financial Transactions for Anti-Money Laundering Models*. 2023. Datasets and Benchmarks Track, NeurIPS.

BAIGABYL, R.; NUGUMANOVA, A.; SODNOMOVA, M. Using graph centrality metrics for detection of suspicious transactions. *Scientific Journal of Astana IT University*, v. 22, 2025.

CHENG, D.; ZOU, Y.; XIANG, S. Graph neural networks for financial fraud detection: a review. *Frontiers of Computer Science*, Springer, v. 19, n. 9, p. 199609, 2025.

DONG, X. et al. Spacegnn: Multi-space graph neural network for node anomaly detection with extremely limited labels. In: *International Conference on Learning Representations (ICLR)*. [*S.l.*: *s.n.*], 2025.

JENSEN, R. I. T.; IOSIFIDIS, A. Fighting money laundering with statistics and machine learning. *IEEE Access*, IEEE, v. 11, p. 8889–8903, 2023.

KARIM, M. R. et al. Scalable semi-supervised graph learning techniques for anti money laundering. *IEEE Access*, IEEE, v. 12, 2024.

LIU, K. et al. Bond: Benchmarking unsupervised outlier node detection on static attributed graphs. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [*S.l.*: *s.n.*], 2022.

OLIVEIRA, R. M. A.; SANT'ANNA, A. M. O.; FERREIRA, P. H. Complex networks-based anomaly detection for financial transactions in anti-money laundering. *Forensic Science International: Digital Investigation*, Elsevier, v. 55, p. 302005, 2025.

RAASVELDT, M.; MÜHLEISEN, H. Duckdb: an embeddable analytical database. In: *Proceedings of the 2019 International Conference on Management of Data*. [*S.l.*: *s.n.*], 2019. p. 1981–1984.

RIONDATO, M.; KORNAROPOULOS, E. M. Fast approximation of betweenness centrality through sampling. *Data Mining and Knowledge Discovery*, Springer, v. 30, n. 2, p. 438–475, 2016.

SHUKLA, S.; JAISWAL, T.; PARMAR, S. A smote-based xgboost model for effective money laundering transaction detection using synthetic data. In: IEEE. *2025 IEEE International Conference on Advances in Computing Research On Science Engineering and Technology (ACROSET)*. [*S.l.*], 2025.

SIZAN, M. M. H. et al. Machine learning-based unsupervised ensemble approach for detecting new money laundering typologies in transaction graphs. *International Journal of Applied Mathematics*, v. 38, n. 2s, 2025.

TRAAG, V. A.; WALTMAN, L.; ECK, N. J. van. From louvain to leiden: guaranteeing well-connected communities. *Scientific reports*, Nature Publishing Group, v. 9, n. 1, p. 1–12, 2019.

United Nations Office on Drugs and Crime. *Estimating Illicit Financial Flows Resulting from Drug Trafficking and Other Transnational Organized Crimes*. Vienna: [*s.n.*], 2011. Disponível em: https://www.unodc.org/documents/data-and-analysis/Studies/Illicit_financial_flows_2011_web.pdf. Acesso em: 26 mar. 2026.

UNIVERSIDADE DO ESTADO DO RIO DE JANEIRO. *Roteiro para apresentação das teses e dissertações da Universidade do Estado do Rio de Janeiro*. Organização de Simone Faury Dib and Neusa Cardim da Silva. Colaboração de Kalina Rita Oliveira da Silva e Rosane Lopes Machado. 2. ed. rev. atual. e ampl. Rio de Janeiro: UERJ, Rede Sirius, 2012. 142 p. Disponível em: https://www.rsirius.uerj.br/extras/downloads/roteiro_de_teses_e_dissertacoes.pdf. Acesso em: 30 dez. 2023.

VASSALLO, D.; VELLA, V.; ELLUL, J. Application of gradient boosting algorithms for anti-money laundering in cryptocurrencies. *SN Computer Science*, Springer, v. 2, n. 143, 2021.

VILELLA, S. et al. Weirdnodes: centrality based anomaly detection on temporal networks for the anti-financial crime domain. *Applied Network Science*, Springer, v. 10, n. 14, 2025.